

0 绪论

0.1 前言

在大部分高校、大部分专业的教学过程中，理论的讲授解决一直是重中之重，实验或观测的实践学习也在近年来得到了越来越多的重视。相比而言，数值与计算方法则长期被置于次要、从属的地位。然而，随着研究系统的逐步庞大、复杂、细致化，理论解析及实验方法皆遇到了可解性、可表征性、海量数据解读等诸多瓶颈。此时，数值计算的重要性就逐步得到凸显。时至今日，小到晶体中的电子本征态、大到可观测宇宙的大尺度结构，相关的研究皆无法离开数值计算的帮助，更不必说存在于建筑力学、航空工程、武器装备、信息网络、经济社科，乃至交通物流、资本市场、人力资源、视听娱乐等人类生产生活的方方面面中，林林总总而无处不在的数值计算的关键应用。

具体到天文及天体物理研究的环境中，计算和数值模拟同样是重要的方法，承担着连接理论与观测的重要职责，现代大量前沿天体物理学研究结果也以计算方法作为核心或重要支撑。同时，计算方法在理论探索和观测数据处理过程中有着无可替代的重要性，其结论及方法在其他研究领域中也有着重要作用。本课程计划对天体物理中数值计算的概念、方法与应用作一初步的介绍与讲解。

0.1.1 近年来数值计算发展状况之管窥

作为计算机科学、物理学、应用数学的交叉点，数值计算是一门方兴未艾的学科，从学术界到产业界、金融界，从计算理论到编程实践、软件工程，时常有突破性、革命性的进展出现，这些进展对经济及生产活动、人们的日常生活乃至文化人文，都带来了翻天覆地的改变。授课者在最近十年的学习和研究过程中，对这一学科所发生的重大改变有以下管窥之见。

首先是机器学习技术的爆发式发展。虽然神经网络的表示定理早已被提出，但在反向传播算法得到大力发展、新型硬件（特别是图形处理器，简称 GPU）取得突破进步之前，机器学习往往被限于决策树、支持向量机等经典而简单的方法上，取得的应用也较为有限。在算法和硬件上取得突破之后，深度神经网络及其多个变种的应用实践及理论研究出现了井喷，其蓬勃之貌甚至形成了全新的庞大产业，其进一步发展及应用也被中美等世界主要国家以国策的形式予以支持。而在数值计算上，授课者认为，机器学习须褪去其在业界蓬勃发展中积累的光环与泡沫，回归其“函数表示法”的本质，方能协助我们取得可靠、可信、可解读的科研进展。

其次是并行计算和异构计算的需求极大增加。大约在 2005 年以前，计算机硬件的发展往往集中在增加中央处理器（CPU）与随机存储器（RAM，惯称内存）的时钟频率上；但在 CPU 的时钟频率大致到达 3 GHz 之后，这一进程却看上去几乎停滞了，其原因主要是热力学上的——若继续增加时钟频率，则充分散热的成本将飙升至不可接受。因此，人们开始向广度发展，寻求如何使更多的计算设备同时参与计算过程中，包括使用多核心处理器、多节点集群，也包括使用异构化的计算设备。这一发展还带来一个微妙的变化：关于单精度（通常意味着 32 位二进制浮点数，简记为 FP32）与半精度（简记为 FP16）的讨论明显增多。从 2000 年左右起，双精度浮点数（一般指 FP64）已经几乎完全取代 FP32（除内存敏感情形外）；但近十年来，由于异构硬件（尤其是 GPU）的异军突起以及机器学习技术的广泛应用，适配这些软硬件方法的 FP32 乃至 FP16 的算法再度获得人们的关注。

0.1.2 本课程的特点——天体物理数值模拟及相关内容

相比于一般的计算物理或工程数值仿真问题，天体物理问题所涉及的数值方法也有其自身的一些特点。在实验及观测方面，天文观测及后续数据处理上所需要的计算技术具有一定特殊性；其往往不位于一般的计算物理课程的覆盖面中，也与计算天体物理的本意不大重合。因此，这一方面的知识往往由专门的观测天文学课程（如《实测天体物理》等）讲授。限于课时及授课者专业方向，本课程不会着力覆盖这些内容（但仍然可能有少量重叠）。在理论方面，描述天体物理系统的物理及数学模型以微分方程（包括常微分及偏微分方程，特别是**天体力学**方程组、**化学动力学**方程组、**流体力学**方程组、**电磁场**的麦克斯韦方程组，以及更一般地描述相空间中运动规律的**玻尔兹曼方程**等）为主，因而其数值建模工作也将以对这些微分方程的求解为主；这与现代计算物理高度突出蒙特卡洛方法（粒子模拟、高维积分等）与特征系统求解（量子力学中哈密顿算符的本征值与本征态等）的内容主干存在着较大的差异。综上，本课程的主干内容可以简要概括为——**解微分方程**。

需要指出的是线性方程组的求解问题。这是一个具有普遍意义的课题；由于绝大部分数值计算问题（包括微分方程在内）可在某种程度上被转化为线性方程的求解，故有大量观点认为数值计算即是求解线性方程组，或曰“解矩阵”。本课程不评论此观点的是非，但授课者结合自身的科研实践认为，矩阵论固然是从理论上分析或导出数值方法的有力工具，但若凡事诉诸矩阵论，却往往会在实践中发生喧宾夺主、削足适履的情况（本课程晚些时候将举出例子）。因此，本课程并不计划以矩阵（包括稀疏矩阵）求解为主干，而是将实践与实现作主要的逻辑线索；与矩阵相关的论述将被分散和穿插到更贴近物理图像与研究实践的讲解中去。

0.2 数值计算的经典命题与简易基础

在开始整个课程之前，我们先快速浏览一遍科研实践中最常用上的部分方法和技术。注意，尽管这些技术很常用，看上去也很简单、直接，但千万不要以为它们是“过时”、“无聊”、“不重要”的事情——因为它们的基本、基础、无处不在，对其在任何意义上进行的任何改进，都将为众多依赖数值计算进行的工作带来巨大的便利。时至今日，仍有许多研究者以此为博士论文研究对象乃至终生的事业，其中不时亦有革命性的重大突破传出。受到课时数量的限制，对这些领域进行全面系统的介绍并不现实，故本部分对它们最基本的内容进行一快速简洁的介绍，以期对数值计算的实行方式有一最基本的认识，并作为整个课程的一部分基础内容。

0.2.1 数值误差和算法阶数：从求导说起

若有一足够光滑的函数 $f(x)$ 可在任意处数值求值，得出其在 x_0 处的数值导数似乎是轻而易举的事，只须取一个足够小的长度 h （称为“步长”；类似概念在后面的章节中还将反复出现），并以差商近似微商（导数）：

$$f'(x_0) \simeq \frac{f(x_0 + h) - f(x_0)}{h}. \quad (1)$$

注意此处的 h 的符号并未指定，故差商可向左或向右进行。然而在实践中，除非有特殊目的（例如希望在双曲偏微分方程求解中避免破坏因果律，本课程对应章节会提及），一般情形下、只须获取导数的数值时，人们往往采取另一种取差商的方式（将微商转化为差商的方式被广泛地用“差分格式”指代）：

$$f'(x_0) \simeq \frac{f(x_0 + h) - f(x_0 - h)}{2h}. \quad (2)$$

这样的方式被称为中心差商。相比于偏置差商，中心差商有何特点？考虑 $f(x)$ 在 x_0 点附近的泰勒展开，

$$f(x) \simeq f(x_0) + (x - x_0)f'(x_0) + \frac{(x - x_0)^2}{2!}f''(x_0) + \frac{(x - x_0)^3}{3!}f^{(3)}(x_0) \cdots \quad (3)$$

分别将 $x \rightarrow x_0$ 与 $x \rightarrow (x_0 + h)$ 代入上式并相减，可得：

$$\frac{f(x_0 + h) - f(x_0)}{h} = f'(x_0) + \frac{h}{2}f''(x_0) + \cdots = f'(x_0) + O(h), \quad (4)$$

其中 $O(h)$ 表示与 h 同量级的数量（此记法被称为“同阶量”，也有以“余项”指代者，或俗称“大 O 记号”）。而对中心差商格式进行同样操作时，与二阶导数有关的 $(x - x_0)^2 f''(x_0)$ 一项被消去了，从而：

$$\frac{f(x_0 + h) - f(x_0 - h)}{2h} = f'(x_0) + O(h^2). \quad (5)$$

可见在 h 足够小时，中心差商估计所得的导数比偏置差商更小。更一般地，我们将数值算法以泰勒展开为基础进行分析，则会发现进入最终结果的部分势必在有限阶处截断，而须抛弃高于某一阶的所有信息。这一类可以归因于“对级数进行截断”所致的数值误差，称为**截断误差**（truncation error）。由于此处中心差商的余项是 h 的二阶项，阶数高于偏置差商的余项（ h 的一阶项），我们称中心差商比偏置差商方法更“高阶”；在 h 变小时，中心差商的结果原则上将比偏置差商更快地趋于 $f'(x_0)$ 。算法的“阶数”是算法设计与应用时的重要考虑因素之一：高阶的算法可能提升计算的准确性，但计算代价很可能也将大幅提升；甚至有时受限于其他方面的数值格式、算法稳定性等各种因素，高阶算法会变得完全不可取。因此，高低阶的优劣不可一概而论。

除了差分格式， h 本身也有值得探讨之处。在数学上， h 越小，则以差商估计的导数距离真实值的偏差就越小；但在数值计算上却非如此。正如前文所说，计算机一般情况下是使用浮点数对实数进行近似表达的，而浮点数本身的相对精度是有限的（实验物理学家与部分领域的工程师常常对“精密度”与“准确度”进行严格的定义与区分，但这两者在数值计算领域因为计算机特别是浮点数运算本身的特性而经常交织，故本课程将沿用数值分析的惯例，用“精度”简单代指）。这将带来一个问题：因函数值的差分须从两点上的函数值相减得出，差值的**绝对精度**与参与相减的函数原值一致，但差值的绝对值比函数原值小得多，故差值的**相对精度**将受到差值自身绝对值的影响。若 h 过小，则因参与相减的函数值过于接近、差值绝对值过小，差值的相对精度将急剧下降，致使最终导数估计值的准确度急剧下降。作为示例，我们令 $f(x) = -e^{-x}$ ，以中心差商格式，使用不同的 h 求取 $x_0 = 1$ 处的 $f'(x_0)$ 值（其“真值”显然为 $e^{-1} = 0.36787944117144233$ ），并将不同 h 时的计算结果列于表 1 中。这一类本质上由于浮点数的有限精度而导致的数值误差，一般称为**舍入误差**（round-off error 或 rounding error）。在实践上，舍入误差的更具象、常见的体现，在于**对加减法保持警惕**——特别是对“很接近的大数相减”的高度警惕。在本课程后期的学习中，我们不会反复地、特意地指出它，但也会发现这一问题的无处不在。与此同时，正如前文所提到的，随着多样化的先进计算硬件的发展，对 FP32 甚至 FP16 的算力的合理乃至集中运用的问题，重新进入了数值计算工作者的视野；此时的舍入误差问题将进一步被暴露在聚光灯下，值得许多系统而深入的研究。

0.2.2 非线性方程求解与迭代

非线性方程的求解是许多计算问题中的关键步骤，甚至很多情况下就是问题本身——例如微引力透镜问题通常可归结于五次代数方程的求解（注意：一般的五次代数方程没有求根公式，这是代数学的经典结论）。试图一蹴而就地求解一个非线性的方程通常是不现实的，我们往往需要通过别的方法求解。

表 1: 不同步长下的数值求导误差示例; 函数为 $f(x) = -e^{-x}$, 求导位置 $x = 1$

h	$f(x+h)$	$f(x-h)$	$f(x+h) - f(x-h)$	数值导数	相对误差
10^{-1}	0.406569659740599	0.332871083698080	0.073698576042520	0.368492880212598	1.667500×10^{-3}
10^{-3}	0.368247504613663	0.367511745608694	0.000735759004969	0.367879502484653	1.666666×10^{-7}
10^{-5}	0.367883119984248	0.367875762395425	0.000007357588824	0.367879441176555	1.389777×10^{-11}
10^{-7}	0.367879477959388	0.367879404383500	0.000000073575888	0.367879441076635	2.577129×10^{-10}
10^{-9}	0.367879441539322	0.367879440803563	0.000000000735759	0.367879449125752	2.162206×10^{-8}
10^{-11}	0.367879441175121	0.367879441167764	0.000000000007358	0.367877950324669	4.052542×10^{-6}
10^{-13}	0.367879441171479	0.367879441171406	0.000000000000074	0.367761376907083	3.209319×10^{-4}

本小节将方程记为 $f(x) = 0$ 。对此方程而言, 若对其求导数 (包括解析求导后代入数值, 及数值求导) 是可行且简便的, 则最常见、有效、图像清晰的求解方式即为所谓的牛顿法。我们首先猜测一个解 $x^{(0)}$, 代入函数后发现其值与 0 尚有差距, 记为 $f(x^{(0)})$; 应该如何在改进猜测、使 $f(x)$ 与 0 更为接近呢? 牛顿给出的答案是, 通过一个递推式, 逐步改进解的猜测值:

$$x^{(n+1)} = x^{(n)} - \frac{f(x^{(n)})}{f'(x^{(n)})}. \quad (6)$$

极易证明, 若 $f(x)$ 为一线性函数则上式将进一步到位地给出精确结果, 若非, 则上式等效于将 $f(x)$ 在 $x^{(n)}$ 附近近似为线性函数并求解这个近似方程, 以期在下一步给出令 $f(x)$ 更接近零的 $x^{(n+1)}$ 作为方程解的一个更好近似。依赖递推关系逐步逼近结果的计算方式一般被称为**迭代** (iteration), 若逐步逼近真实结果的目标得以实现则称此迭代是**收敛** (converge) 的。上述方程求解的数值方法一般称为牛顿法、切线法, 或牛顿——拉夫森迭代。当 $f(x)$ 因各种原因无法解析求导, 我们固然可以在各点以数值方法求其导数, 但有一个节省计算代价的方案是使用上一步的结果对导数进行估计:

$$x^{(n+1)} = x^{(n)} - \frac{f(x^{(n)})}{s^{(n)}}, \quad s^{(n)} \equiv \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}}. \quad (7)$$

几何上, 这一方法等效于用第 $n-1$ 步到第 n 步的 x 及 $f(x)$ 值所形成的函数的割线近似替代切线, 故也称为割线法。在实践中, $f(x)$ 的计算有时是极其复杂且昂贵的 (如本课程晚些时候讲述的常微分方程边值问题的打靶法, 其等效的函数值求解须对整个常微分方程组进行积分), 此时相较于直接数值求导, 割线法可省下巨大的计算代价。

尽管简单、易行, 切线或割线法也并非应对非线性方程求解问题一劳永逸的万灵药。若某次迭代给出的 $f'(x^{(n)})$ 或 $s^{(n)}$ 极其接近零, 则上述方法将导致 $x^{(n+1)}$ 相比 $x^{(n)}$ “冲出” 一段非常远的距离, 破坏 “逐步逼近” 的目标。因此, 我们往往须对 $x^{(n+1)} - x^{(n)}$ 的 “改进幅度” (也叫步长) 作出一定限制以免数值求解失败, 或在导数过于接近零时采用别的方法 (如更低阶的所谓不动点方法, 或者更高阶、使用二阶导数的方法, 此处不展开)。另外, 即便导数与零尚有距离, 此类方法仍不能保证收敛。一个著名的例子是 (sgn 为符号函数),

$$f(x) = \text{sgn}(x-1)|x-1|^{1/2}. \quad (8)$$

这一方程的解显然为 $x = 1$ 。该函数除 $x = 1$ 外处处光滑, 导数也不难解析求得, 然而标准的牛顿法甚至完全无法获得结果 (参见图 1)。容易证明, 标准的牛顿法将导致 $x^{(n+1)} = 2 - x^{(n)}$, 迭代序列将在




图 1: 牛顿法失效示例: 函数为 $f(x) = \text{sgn}(x-1)|x-1|^{1/2}$, 从猜测值 $x = 0.5$ 开始。

$x^{(0)}$ 与 $2 - x^{(0)}$ 两者上反复跳跃。此时采取割线法可以获得正确的结果, 前述的限制步长的方法也同样有效, 但逼近真实解所需的迭代次数仍然很多 (称为“收敛速率慢”), 故也需要适时采用其他方法。一般而言, 面向实际、因地制宜是数值计算工作者必备的素质和技能。

0.2.3 线性插值

插值是数值分析中经典而常见的问题, 而一维线性插值是最基础的方法之一。若已知两点 x_0 、 x_1 及其对应位置的函数值 $f(x_0)$ 、 $f(x_1)$, 则在区间 $[\min\{x_0, x_1\}, \max\{x_0, x_1\}]$ 中的任意点 x 上, 线性插值所给出的结果即为:

$$\tilde{f}(x) = f(x_0) + \frac{f(x_1) - f(x_0)}{x_1 - x_0}(x - x_0). \quad (9)$$

这一方法的数学图像非常明晰: 用两点间的一阶导数估计函数在区间内的变化状况, 借此估计函数值。可以证明, 这一算法保证了 x_0 与 x_1 交换时的结果不变。

下面将这一问题拓展至高维。简单起见, 考虑一个略显特殊但仍极为常见的情形: 将空间打上网格, 且令网格成行成列, 每行沿坐标线铺开, 且各行 (沿同一坐标变量的坐标线铺开的) 格点的变动坐标分布完全相同 (注意, 可以不均匀)。不太严格地说, 这一网格分布方式称为**结构网格** (不满足这些条件的网格称为**非结构网格**, 如三角形面元网格、四面体网格等; 非结构网格插值本课程暂不拟涉及)。在结构网格各格点上, 给定了函数的值, 且格点坐标已知, 这一情形称为结构化插值 (否则称为非结构插值, 同样暂不涉及)。

以二维结构插值为例。假设我们已知结构化网格中构成一长方形的四个顶点 $\{x_0, x_1\} \otimes \{y_0, y_1\}$ 上的函数数值 $f(x_{0,1}, y_{0,1})$, 如何借此近似给出此长方形内部任意点 ($x \in [x_0, x_1]$, $y \in [y_0, y_1]$) 处的函数值? 我们首先指定此插值函数的形式 (此处 $\{a_{ij}\}$ 为一组待定系数):

$$\tilde{f}(x, y) = a_{00} + a_{10}x + a_{01}y + a_{11}xy = [1, x, y, xy][a_0, a_{10}, a_{01}, a_{11}]^T = [1, x] \begin{bmatrix} a_{00} & a_{01} \\ a_{10} & a_{11} \end{bmatrix} \begin{bmatrix} 1 \\ y \end{bmatrix}. \quad (10)$$

当固定 y 时, 上式对 x 是一线性函数, 反之亦然; 形式上, 它是 $[1, x]$ 与 $[1, y]$ 两个向量的双线性形, 故该方法因此被称为**双线性插值**。如何给定这些系数? 插值的基本要求是在作为输入给定的坐标点上

给出与输入一致的函数值，于是可得对待定系数（或称矩阵元） $\{a_{ij}\}$ 的约束：

$$\begin{bmatrix} \tilde{f}(x_0, y_0) \\ \tilde{f}(x_0, y_1) \\ \tilde{f}(x_1, y_0) \\ \tilde{f}(x_1, y_1) \end{bmatrix} = \begin{bmatrix} 1 & x_0 & y_0 & x_0 y_0 \\ 1 & x_0 & y_1 & x_0 y_1 \\ 1 & x_1 & y_0 & x_1 y_0 \\ 1 & x_1 & y_1 & x_1 y_1 \end{bmatrix} \begin{bmatrix} a_{00} \\ a_{10} \\ a_{01} \\ a_{11} \end{bmatrix} = \begin{bmatrix} f(x_0, y_0) \\ f(x_0, y_1) \\ f(x_1, y_0) \\ f(x_1, y_1) \end{bmatrix}. \quad (11)$$

上式中的矩阵称为范德蒙德矩阵。求解这一线性方程组，我们便获得了各系数的值。通过对结果的观察，人们发现一个有趣的情况：上述插值可等效为四个函数值 $f(x_{0,1}, y_{0,1})$ 的加权平均；对每个输入点而言，它的权重在正好等于它对侧的长方形面积对 $[x_0, x_1] \otimes [y_0, y_1]$ 整个矩形区域面积的比值（这一状况来源于范德蒙德矩阵的数学意义和性质）：

$$\tilde{f}(x, y) = \sum_{i,j=0}^1 w_{ij}(x, y) f(x_i, y_j), \quad w_{ij}(x, y) = \frac{|x - x_{1-i}| |y - y_{1-j}|}{(x_1 - x_0)(y_1 - y_0)}. \quad (12)$$

以上所有对双线性插值的论证与方法可以方便地拓展至高维情况，此时该方法称为**多线性插值**。

0.2.4 算法复杂度：克莱默法则的成败

克莱默法则（Cramer's rule）是代数学中的关键结论，在数学史上有重要地位，且是许多更深入的数学结论的基础。我们不经证明陈述其内容：若有一线性方程组 $Ax = b$ ，其中 A 为 $n \times n$ 的方阵，则其解可表示为：

$$x = A^{-1}b, \quad A_{ij}^{-1} = \frac{\det(A_{ij})}{\det(A)}, \quad (13)$$

其中 $\det$ 指行列式，而 $\det(A_{ij})$ 是矩阵 A 对第 i 行第 j 列的代数余子式（即将矩阵 A 第 i 行第 j 列剔除后的剩余部分所构成的行列式）。这一表达式简洁优美，但在计算实践中没有价值：几乎没有任何人以此解决线性方程组问题；出现这一情形的原因主要是计算代价。设 $A \equiv \{a_{ij}\}$ 为 A 的矩阵元，则根据行列式的定义（ π 指代指标 $i_0, \dots, i_{n-1}$ 的所有可能的互异排列，而 τ 指代这一排列的奇偶性），

$$\det(A) = \sum_{\pi(i_0, \dots, i_{n-1})} (-1)^{\tau(i_0, \dots, i_{n-1})} a_{0,i_0} a_{1,i_1} \cdots a_{(n-1),i_{n-1}}. \quad (14)$$

这一表达式须对 $n!$ 个乘积进行求和，每个乘积须进行 $(n-1)$ 次乘法。相应地，代数余子式的行列式须进行 $(n-2)(n-1)!$ 次乘法，共须进行 n^2 次代数余子式运算。总之，按克莱默法则，得出 A^{-1} 一共须进行 $(n^2 - n - 1)n! \simeq n^2 n!$ 次乘法；只要 $n \geq 3$ ， A^{-1} 与 b 相乘时所需的 n^2 次运算在如此庞大的代价前显得微不足道。此时，我们以乘法次数计，同样借助“大 O 记号”，称此种方式给出的线性方程组求解的算法复杂度为 $O(n^2 n!)$ 。显而易见，这是一个大得惊人的复杂度，此结果也直接致使它没有任何数值上的实用价值。事实上，矩阵行列式计算的通行算法往往依赖矩阵的 LU 分解（本课程后续有讲解），其复杂度为 $O(n^3)$ ，远远优于借助行列式定义计算的克莱默法则本身。但是， LU 分解本身就是求解线性方程组的最常用方法之一，进行完毕的分解可直接用于求解方程组。于是，上述论证彻底宣判了克莱默法则在计算领域的淘汰出局。

与此类似地，“数学上完美、数值上无用”的情形在以后的课程与科研实践中会常常遇到；其中有一部分是因为数值精度方面的问题，但更常见的往往同样是计算代价带来的问题。相应地，对算法的计算复杂度的改进，在数值上的意义完全不亚于（甚至常常远超）提出理论上完美的方法；一个典型而著

名的例子是从离散傅里叶变换到快速傅里叶变换的算法改进（本课程晚些时候也将提及）——这一改进使离散傅里叶变换的复杂度从 $O(n^2)$ 变为 $O(n \log n)$ ，让傅里叶变换成为一种可行且实用的算法，进而使计算技术从最底层的硬件到直接与用户交互的音视频媒体的各个层面都发生了翻天覆地的革命性变化。总之，包括（或曰特别是）计算天体物理在内，数值计算领域的研究皆具有较为浓重的工程学色彩：相比于理论上的完美，实践中的调整、权衡、因地制宜乃至“见招拆招”，才是解决问题的关键。

习题

注意：绪论课的习题不以算法教学为绝对目的，而以适应、习惯数值计算及其表现为目标。本次作业中，你可以使用成熟、成型的数学库函数（尽管自行撰写的难度其实也很低，强烈推荐有时间的学习者自行撰写），如 Python 上的 numpy、scipy，C/C++ 上的 GSL (GNU Science Library；Fortran 上有经过“包装”的 GSL)，甚至 Matlab、Mathematica 等成套软件。当我们进行到后面的章节，算法本身的学习将成为核心；彼时除非特殊情形，成熟的数值计算库或软件将不再允许在作业中使用。

习题 0.1. 假定你是一名星系模拟的专家，刚刚通过某些手段（通常是星系动力学模拟基础上的星族合成，stellar population synthesis）得出了一个假设中的星系的光谱。为了与观测进行对比，你希望知道这个星系在斯隆数字化巡天（Sloan Digital Sky Survey，简称 SDSS）的测光系统中所呈现的数据。

1. 搜集搜索获得公开数据是科研工作者的必备技能。请自行搜索和下载 SDSS 的五个测光滤光片的透过率作为波长的函数（或称“窗函数”），将其读取到你的程序中，并将其绘制在同一张图中（注意：请设法让读者能够清晰阅读）。若确实无法自行获取，请联系任课教师索取。
2. 请联系任课教师获取这个星系的光谱（注意，这是未经红移的光谱），读取并绘制该光谱——请注意横纵坐标轴的标度方式（线性或对数）以及绘制范围。借助上一问中获得的滤光片数据，假定星系在我们附近（即 $z = 0$ ），请给出对其观测时 g 与 r 两个波段的流量之比（SDSS 的星等有较为特殊的定义，此处略过）。这一问中，除了课上提及的某些技术，你还须使用一个讲义上并未提及但仍然极其重要的计算技术——数值积分；此处使用最简单的数值积分方法即可，但请简述你是如何进行数值积分的。注意，积分时候难免遇到超出某些数据的波长范围或存在大量冗余数据的情况，请自行决定是否舍弃部分数据。
3. 与你合作的观测天文学家希望知道这个星系在不同红移处所呈现的颜色指数。请计算并绘制其 g 与 r 波段流量比在红移 $z \in [0, 3]$ 范围内的变化情况。提示：无须考虑星系演化，只须改动光谱波长即可。

习题 0.2. 这是一道证明及简答题，无须撰写和提交代码。

1. 课程中提及了多线性插值的一般方法，即求解范德蒙德矩阵。然而对结构化的双线性插值而言，还有一个非常直观的想法：先在 $y = y_0$ 、 $y = y_1$ 两条直线上先沿 x 方向进行两次一维线性插值：

$$f^{(0,1)} \equiv f(x_0, y_{0,1}) + \frac{f(x_1, y_{0,1}) - f(x_0, y_{0,1})}{x_1 - x_0}(x - x_0),$$

再沿 y 方向进行一次一维线性插值：

$$f(x, y) = f^{(0)} + \frac{f^{(1)} - f^{(0)}}{y_1 - y_0}(y - y_0).$$

请证明这一方法与课程正文 (§0.2.3) 所述方法数学上等效。注意，此证明应可方便推广至任意维数，故请尽可能简洁，千万不要“硬算”。

2. 实践中，人们经常对多线性插值系统进行坐标变换。考虑一个简单情形：以 $\{[x_i, y_j], f(x_i, y_j)\}$ ($i, j = 0, 1$) 共四个点为输入的双线性插值，往往会在 $x' = x - x_0$ 、 $y' = y - y_0$ 的坐标变换后进行。试证明这样的变换数学上与不进行变换的结果等效（同样，这个证明应极简洁，并可方便推广至高维）。然而，数学上的等效并不意味着数值上的等效；这样的坐标变换在数值计算上会带来什么好处？

1 常微分方程

我们将只有一个自变量的微分方程称为“常微分方程”(ordinary differential equation, 简称 ODE)。当有多个因变量取决于同一个自变量时, 称为常微分方程组。 N 阶常微分方程组的最一般形式如下^{1 2}

$$\frac{d^N y_i}{dx^N} = f_i \left(\{y_j\}, \left\{ \frac{dy_j}{dx} \right\}, \dots, \left\{ \frac{d^{N-1} y_j}{dx^{N-1}} \right\}, x \right), \quad \forall i, j. \quad (1)$$

当我们对 $N > 1$ 的高阶常微分方程组进行数值求解时, 可以使用一个简单技巧对其降阶: 将因变量 y_i 的每一个高阶导数都当做一个“新的”、独立的因变量, 记为 $\tilde{y}_i^{(n)} \equiv d^n y_i / dx^n$ 。这时, 上述方程组转化为一个一阶常微分方程组:


$$\frac{d\tilde{y}_i^{(N-1)}}{dx} = f_i \left(\{y_j\}, \{\tilde{y}_j^{(1)}\}, \dots, \{\tilde{y}_j^{(N-1)}\}, x \right), \quad \frac{d\tilde{y}_i^{(N-2)}}{dx} = \tilde{y}_i^{(N-1)}, \dots, \frac{dy_i}{dx} = \tilde{y}_i^{(1)}. \quad (2)$$

需要注意的是, 对 $d^n y_i / dx^n$ 生效的约束(初始条件、边界条件等)也应当体现在 $\tilde{y}_i^{(n)}$ 上。在后文中, 我们一般只讨论一阶常微分方程组的数值求解。

尽管对微分方程求解前先进行无量纲化似乎是一种惯例, 但需要说明的是, “是否要对物理方程进行无量纲化”的问题是必须针对具体研究对象回答的。当我们研究的物理问题的机制较为单纯、不涉及多种不同原理或尺度的机制的相互耦合时(如纯粹的流体力学问题), 对体系进行无量纲化有助于拓展研究结论的适用范围, 并使得结果更具有揭示性、启发性, 更易抓住重点, 也更适合数学领域的研究人员理解其关键。然而, 当多重物理机制的耦合成为研究的要素乃至核心时(例如, 化学及热力学过程与流体力学的耦合, 即所谓“反应流”问题), 每种物理机制将会各自有其方便的无量纲化方案。量纲分析告诉我们, 这些无量纲化方案往往彼此并不兼容(“白金汉 Π 定理”, 即量纲空间的维度分析; 参见谈庆明 2007 §2.2), 须以其中一种无量纲化方案为基础, 对其他物理机制所涉及的表达式进行无量纲化——这一操作常常显得非常“别扭”。“并非源自其本身物理机制的无量纲化方案”有时会使得表达式变得非常复杂³, 有量纲物理量所具备的“依靠量纲进行结果检查”等便利或优势也将不复存在, 表达式的书写、录入及编程将变得极易出错。因而, 是否要进行全面的无量纲化, 并不能一概而论。

1.1 初值问题: Chem-is-try

氢是宇宙中最简单、最丰富的化学元素, 与氢有关的反应也是最为天文学研究者熟知的反应。考虑如下的简单问题(这类问题一般属于化学动力学的范畴, 更详尽的讨论参见专门的物理化学教材)。在 3100 K 温度下, 原子氢与 $h\nu = 14$ eV 单色光相互作用时, 体系中主要存在着光致电离与复合反应:



这里我们选取了 $h\nu = 14$ eV 的光致电离截面 σ , 并选取了 3100 K 下的 A 类复合常数(即认为复合过程辐射的光子可全部逃逸)作为复合反应的速率系数 k (参见 Draine 2011, §13.1、§14.2)。在此情

¹ 请注意: 在书写表达式时, 原则上应当用斜体表达单字母变量, 用正体表达除此之外的一切符号(包括单位和量纲、微分算符、多字母无量纲数等)。涉及常量时, 若可理解为变量的特殊情况则也应当用斜体, 如光速 c 、太阳质量 $M_\odot$ 等。

² 本文中我们将使用爱因斯坦指标约定: 当一个指标单独出现意味着该指标“走遍”所有可取值, 当直接相乘的变量中指标成对出现时须对该指标取所有可能值的状态求和, 也即: a_i 意味着 $\{a_i\}$, $\forall i$; $a_i b_i$ 意味着 $\sum_i a_i b_i$ 。

³ 一个极端但现实存在的例子是, 以膨胀宇宙中的流体力学为基础进行的无量纲化, 会使得其中的辐射冷却的表达式复杂到难以理解。

形下, 若忽略复合时对低动能电子的选择性吸收增强, 每个电离事件给系统带来的额外能量皆等于平均热动能, 每个复合事件带走的能量也不多于游离时的热动能; 若额外假定体系定容, 则温度将保持不变, 可作等温处理。在等温定容的前提下, 体系中氢原子、氢离子、自由电子浓度 (粒子数密度) 随时间的变化满足如下常微分方程组:

$$\frac{dn(\text{H}^+)}{dt} = \frac{dn(\text{e}^-)}{dt} = \left[-\frac{dn(\text{H})}{dt} \right] = \sigma F(14 \text{ eV}) n(\text{H}) - k n(\text{H}^+) n(\text{e}^-). \quad (3)$$

式中, $F(14 \text{ eV})$ 是该单色光的光子流量 (以 $\text{photon cm}^{-2} \text{ s}^{-1}$ 为单位); 复合反应的速率为 $kn(\text{H}^+)n(\text{e}^-)$, 这样的反应速率形式 (速率正比于反应物浓度乘积) 称为质量作用定律 (mass action law)。定义 $n_{\text{H}} \equiv n(\text{H}) + n(\text{H}^+)$ 为氢核总浓度, 并定义氢的电离比 $\xi = n(\text{H}^+)/n_{\text{H}}$ (在此情形下可等同于反应进度参量), 则上述常微分方程组可简化为单一的、无量纲化的微分方程:

$$\frac{d\xi}{d\tau} = \varphi(1 - \xi) - \xi^2, \text{ 其中: } \tau \equiv kn_{\text{H}}t; \varphi \equiv \frac{\sigma F}{kn_{\text{H}}}. \quad (4)$$

虽为非线性常微分方程, 它却有解析解——这为我们对数值求解的方法与结果的检验提供了极大便利。若从全中性开始演化, 该方程的解为:

$$\xi = -\frac{\varphi}{2} + q \tanh \left[q\tau + \operatorname{arctanh} \left(\frac{\varphi}{2q} \right) \right], \quad q \equiv \frac{\sqrt{\varphi(\varphi + 4)}}{2}. \quad (5)$$

显然, $\xi|_{\tau=0} = 0$, 而 $\xi|_{\tau \rightarrow \infty} = [(\varphi^2 + 4\varphi)^{1/2} - \varphi]/2$. 当 $\varphi = 0$ 及 $\varphi \rightarrow \infty$ 时, $\xi|_{\tau \rightarrow \infty}$ 的取值也分别满足各自物理上的直观结果 (分别为 0 和 1)。

1.1.1 最简单的求解: 欧拉方法

欧拉 (Euler) 方法是最简单的常微分方程数值求解方法。若我们已知 $x = x_0$ 时 $\{y_i\}$ 的值, 则 x_1 处的因变量值直接由 x_0 处的导数通过“线性外推”给出,

$$y_i|_{x=x_1} = y_i|_{x=x_0} + (x_1 - x_0) \left[\frac{dy_i}{dx} \right]_{x=x_0}. \quad (6)$$

本步骤中“行走的距离” ($\Delta x \equiv x_1 - x_0$) 被称为“步长”。在下一步骤中, 本步的目标自变量 x_1 变成了初始状态 x_0 , 并将相同的程序再次执行。如此往复, 直到自变量 x 抵达所需的最终值。在这一方法的执行中, 只要我们知道导数 (dy_i/dx) 关于所有变量 $\{y_i\}$ 与 x 的表达式 (解析形式、表格插值形式等均可), 求解在原则上就可继续进行。

我们现在尝试将这套方法用于方程 (4), 取 $\varphi = 1$, 从 $\tau = 0$ 及 $\xi|_{\tau=0} = 0$ 出发, 求解至 $\tau = 2$ 。我们使用 $\Delta\tau = 0.4$ 、 $\Delta\tau = 0.2$ 和 $\Delta\tau = 0.1$ 三个不同的步长分别进行求解 (分别须前进 5 步、10 步及 20 步), 将求解结果展现在图 1 中, 并与公式 (5) 所示的解析解进行对比。可以看出, 欧拉法得出的结果与解析解大致符合但仍然存在着一一定的差距。当步长较小时, 这个差距也会减小——当然, 此时计算步骤数更多, 总的计算代价也更高。

欧拉法得出的结果与真实值所存在的差距大小是可以估计的。假设目标函数可以用泰勒级数展开, 则在公式 (6) 所示的 x_1 处, $\{y_i\}$ 的值应为

$$y_i|_{x=x_1} = y_i|_{x=x_0} + \left[\frac{dy_i}{dx} \right]_{x=x_0} \Delta x + \left[\frac{d^2 y_i}{dx^2} \right]_{x=x_0} \frac{\Delta x^2}{2} + \cdots = y_i|_{x=x_0} + \left[\frac{dy_i}{dx} \right]_{x=x_0} \Delta x + O(\Delta x^2). \quad (7)$$

式中 $O(\Delta x^2)$ 意味着与 $\Delta x^2 \equiv (\Delta x)^2$ 同阶的项。由此可见, 欧拉法每一步的误差正比于 Δx^2 , 但总的步数反比于 Δx , 故整体的误差正比于 Δx 的一次方——我们因此称欧拉方法具有一阶精度。




图 1: 对方程 (4) 的求解结果——展示不同步长下欧拉法 (彩色实线) 求解结果、四阶龙格——库塔法 (红色虚线) 数值求解结果与解析解 (黑色实线) 的对比 (见 §1.1.1)。

1.1.2 高阶方法

如果我们知道 x_0 处的高阶导数, 且待求函数高阶可微分, 则泰勒级数会让我们轻松把算法阶数推向更高——可惜这几乎是不现实的, 我们往往必须立足于一阶导数, 追求更高阶的精度。这里介绍最常见、最负盛名的高阶方法的构造, 可纳入此框架的高阶方法被统称为**龙格——库塔方法**。

该方法的出发点为拉格朗日中值定理——在区间 (x_0, x_1) 上一定存在一点 ξ , 使得 $(y_1 - y_0)/\Delta x = f(\xi)$ 。此处我们将 $x_{0,1}$ 处的 y 值简记为 $y_{0,1}$, 将导数 dy/dx 简记为 f 。如何寻找 $y(\xi)$? 一种思路是, 首先估计区间 $[x_0, x_1)$ 上依次排开的 s 个中间辅助点 $\tilde{x}_i$ ($i = 0, 1, \dots, s-1$) 上的函数值 $\tilde{y}_i$ 进而得出这些点上的导数估计值 $f(\tilde{y}_i, \tilde{x}_i)$, 最终对这些估计值进行加权平均, 估计前述的 $f(\xi)$ 。写作表达式便是:

$$y_1 = y_0 + \Delta x \sum_{i=0}^{s-1} b_i f(\tilde{y}_i, \tilde{x}_i). \quad (8)$$

作为加权平均, 显然须有约束 $\sum_i b_i = 1$ 。进一步地, 龙格——库塔法给出 $\tilde{x}_i$ 并估计 $\tilde{y}_i$ 及相应的 $\tilde{f}_i \equiv f(\tilde{y}_i, \tilde{x}_i)$ 的方法是, 给定 $\tilde{x}_0 = x_0$, $\tilde{y}_0 = y_0$, 且对大于零的整数 i (此处不适用爱因斯坦求和约定):

$$\tilde{x}_i = x_0 + c_i \Delta x, \quad \tilde{y}_i = y_0 + \Delta x \sum_{j=0}^{i-1} a_{ij} \tilde{f}_j, \quad \tilde{f}_i = f(\tilde{y}_i, \tilde{x}_i), \quad i = 1, \dots, s-1. \quad (9)$$

除 $c_0 = 0$ 外, 方法中的系数组 $\{a_{ij}\}$ 、 $\{b_i\}$ 与 $\{c_i\}$ 具体为何, 目前尚未指定, 且其具体数值确实存在一定的自由度。除权重归一化 $\sum_i b_i = 1$ 之外, 另一个经常被采用的约束是 $\sum_j a_{ij} = c_i$: 这会使得公式 (9) 与 (8) 具有相同的形式, 继而意味着公式 (9) 确实以相同逻辑给出了 $\tilde{x}_i$ 处的近似因变量值 $\tilde{y}_i$ 。尽管后者其实并不是算法成立的充分或必要条件, 我们仍将使用这一约束。

在这些约束下, 确定各系数的一个可取思路是: 尽可能使最终结果与泰勒展开对比所成的截断误差, 为 Δx 的尽可能高阶的数量。以 $s = 2$ 为例, 考察其泰勒展开 (例如公式 7), 可将其改写为:

$$y_1 = y_0 + \Delta x f(y_0, x_0) + \frac{\Delta x^2}{2} \left[\frac{\partial f}{\partial x} \Big|_{y_0, x_0} + \frac{\partial f}{\partial y} \Big|_{y_0, x_0} f(y_0, x_0) \right] + O(\Delta x^3). \quad (10)$$

同时, 若将其龙格——库塔法的表达式 (公式 (9)) 进行泰勒展开, 有 (已利用 $\sum_i b_i = 1$):

$$y_1 = y_0 + \Delta x f(y_0, x_0) + \frac{\Delta x^2}{2} \left[2b_1 c_1 \frac{\partial f}{\partial x} \Big|_{y_0, x_0} + 2a_{10} b_1 \frac{\partial f}{\partial y} \Big|_{y_0, x_0} f(y_0, x_0) \right] + O(\Delta x^3). \quad (11)$$




图 2: 同图 1, 但对方程 (4) 取 $\varphi = 20$ 的求解结果; 可见图中展示的各显式方法全部求解失败。

对比公式 (10) 与 (11), 若欲使其相差仅为 $O(\Delta x^3)$, 则应使得 $b_1 c_1 = 1/2$, 且 $a_{10} b_1 = 1/2$ 。结合前面的约束, 我们仍有一自由度 b_1 。人们常取 $b_1 = 1/2$, 继而可得 $b_0 = 1/2$ 、 $c_1 = 1$ 、 $a_{10} = 1$ 。这即是经典的二阶龙格——库塔法, 也称为 Heun 方法。类似地, 若 $s = 4$, 人们最常采取的是 $b_0 = b_3 = 1/6$ 、 $b_1 = b_2 = 1/3$ 、 $c_1 = c_2 = 1/2$ 、 $c_3 = 1$, 以及 $a_{10} = a_{21} = 1/2$ 、 $a_{32} = 1$ (其余 $a_{ij} = 0$) 的经典四阶龙格——库塔法 (在不同程序库等处常简称 RK4), 也即:

$$\begin{aligned}
 \tilde{f}_0 &= f(y_0, x_0); \\
 \tilde{f}_1 &= f(y_0 + \tilde{f}_0 \Delta x / 2, x_0 + \Delta x / 2); \\
 \tilde{f}_2 &= f(y_0 + \tilde{f}_1 \Delta x / 2, x_0 + \Delta x / 2); \\
 \tilde{f}_3 &= f(y_0 + \tilde{f}_2 \Delta x, x_0 + \Delta x); \\
 y_1 &= y_0 + \frac{\Delta x}{6} (\tilde{f}_0 + 2\tilde{f}_1 + 2\tilde{f}_2 + \tilde{f}_3).
 \end{aligned} \tag{12}$$

当人们提及四阶龙格——库塔法, 甚至不加修饰地提及龙格——库塔法时, 所指便是此种方法。当然, 根据不同的需要, 不同阶的龙格——库塔法也在被陆续构造出来, 此处不做陈述。取 $\Delta \tau = 0.2$ 的四阶龙格——库塔法对方程 (4) 进行求解, 结果也展现在图 1 中, 可见在同同步长下, 四阶龙格——库塔法所得结果要远好于欧拉方法。

1.1.3 当方法失效时: 方程组的刚性

我们来对 §1.1.1 做一些调整: 取 $\varphi = 20$ 并同样从 $\tau = 0$ 积分到 $\tau = 2$, 并分别用欧拉法和四阶龙格——库塔法求解 (所用步长与图 1 即 §1.1.1、§1.1.2 中各自相同); 图 2 将数值结果与解析解进行了对比。可以发现, 不论是一阶的欧拉法还是四阶的龙格——库塔法, 我们的求解都失败了。失败的方式往往是, 数值点距离相对“平衡”的位置偏离过大, 在下一步中以巨大的势头冲向相反的方向, 却导致了更大的偏离。

我们一般把此类失败归因于方程的刚性 (注意: 有一些文献认为, 只有当独立的因变量数目至少为 2 时才可将方程组称为刚性的; 这里我们为了方便讨论, 认为对一个方程也可以称刚性)。“刚性” (stiff) 一词来自于结构力学。应用数学家和工程学家们在固体结构 (比如建筑、机械等) 的研究中, 发现了一大难点: 当相互连接的物体的刚度 (可简单理解为应变对应力的比值) 差别较大时, 描述体系的方程会

难以求解。一般来说，这一类结构求解往往是从猜测的初始构型开始，沿着应力的方向（也即能量梯度方向）进行虚拟的“演化”直至收敛，即能量不再改变。在这样的演化中，刚度强的物体稍有形变则会产生巨大的回复力。一旦步长稍大则很容易过冲（“冲过头”，overshoot），与平衡偏差较大的构型所带来的反向回复力则会使得反向运动的过冲更加严重，如是往返，直至求解序列发散，数值求解失败。一个较为直观的解决方法是，取较小的步长、进行更多次的求解，以此避免每一步的过冲。然而，与之相连接的低刚度物体却仍然需要足够的“时间”来响应构型的改变，这导致总的步数随着步长减小而大幅增加。因此，这样的方法虽然偶尔有效，但仍然难以避免计算代价的暴涨，直至无法承担。有时可以通过一些技术，使每步的步长在满足误差要求和稳定性前提下尽可能取最大值，以此避免过多的计算步骤（一般称为自适应步长方法），但并不总能起效。

当方程数目只有一个，而我们从数学或物理图像上确认方程本身收敛，则尚且可以用较小的步长使其达到稳态，再认为系统达到稳态后不再演化。但如果方程数量多于一个、变量间耦合较强，且参与耦合的变量的典型变化速率差距巨大（这是“强刚性”的最典型、最麻烦的情形），我们就必须另寻良策了。有一个数学参量可用于较为方便地衡量刚性强弱——考虑线性常微分方程组：

$$\frac{dy_i}{dx} = J_{ij}y_j + b_i(x), \quad (13)$$

若对矩阵 J_{ij} 进行特征值分解，则其绝对值最大和最小的特征值的模之比，就展现了该方程最快和最慢变化模式的变化速度之比。这就是所谓“刚性比”，它也是矩阵 J_{ij} 的条件数；这个数值越大，方程组的刚性越强（故求解越困难），矩阵也越“病态”。若方程为非线性的，则我们同样可以将 $dy_i/dx = f_i(\{y_j\}, x)$ 对 $\{y_j\}$ 进行泰勒展开并分析其刚性。此时 $J_{ij} \equiv \partial f_i / \partial y_j$ 称为微分方程组的雅可比矩阵。

当然，对雅可比矩阵进行特征值分析往往只具备理论意义。现实中，除非 J_{ij} 的值不变（即方程组确实为线性的），否则反复求解其整个特征系统的代价过于高昂（复杂度一般为 $O(N^3)$ ， N 为矩阵大小），通常是不切实际的。但是，部分、分块的对角化（即将快速和慢速的模式按某个临界值分开）并用具有针对性的方法分别处理微分方程组中快慢分量的演化，正是某些算法的核心。其中典型例子如“计算奇异值微扰”（computational singular perturbation）方法，可在求解的同时追踪雅可比矩阵变化的状况以降低计算代价，常用于研究较大系统（成百上千的化学物种参与反应）的化学动力学（参见 Lam & Goussis 1989）。

值得指出的是，刚性问题及其带来的“麻烦”不仅普遍地存在于数值计算的诸多方面，也存在于科学研究与工程技术的种种领域中——从电力系统到流体力学，从天体轨道到晶体结构，从化工生产到交通安全（可搜索“飞行员诱发振荡”，pilot induced oscillation），从宏观经济到市政规划，等等。对刚性问题的恰当处理（须综合稳定性、准确性、求解代价等多方面问题），是数值计算与应用数学领域内经久不衰的研究课题之一。

1.1.4 来自未来的问候：隐式与半隐式方法

定性地看，“过冲”是造成刚性方程求解失败的根本，而造成“过冲”的原因是使用了步骤开始时的导数值。尽管高阶的多步方法试图估计一步中某处的导数值，但也未能超出“使用当前导数值”的范畴。如果能使用步骤终止处的导数值，使得 $\{y_i\}$ 与 x 在步骤始终点的差商能够给出与终止处导数相符的数值，则“过冲”的问题可以彻底避免——如果终点处存在“过冲”，该处本应导致更严重“过冲”的导数值将会使其自身与差商严重不匹配。若写成表达式，这个想法应表述为：

$$y_i|_{x=x_1} = y_i|_{x=x_0} + (x_1 - x_0) \left[\frac{dy_i}{dx} \right]_{x=x_1}. \quad (14)$$




图 3: 同图 2 (取 $\varphi = 20$) 但使用隐式 (彩色实线)、半隐式 (彩色虚线) 的求解结果; 仅展示 $0 < \tau < 1$ 的区间。

但当我们尚未迈出这一步时, 终点处的导数 $[dy_i/dx]_{x=x_1}$ 从何谈起呢?

事实上, 方程 (14) 应视为 $\{y_i\}_{x_1}$ 的隐函数 (相对地, 方程 6 是其显函数), 我们需要将其当作 $\{y_i\}_{x_1}$ 的方程来求解, 以获得其数值。一般地, 可以通过步骤开始时的因变量及自变量值得步骤末因变量值的方法称为显式方法 (explicit method), 而需要通过求解隐函数方程以获得步骤末结果的方法称为隐式方法 (implicit method)。结合 §1.1.1 的分析可知, 方程 (14) 所示意的方法也具有一阶精度故为一阶隐式方法, 因其表达式与欧拉法非常相近故也被称为反向欧拉法 (backward Euler method)。

对于简单的情形, 方程 (14) 的求解是容易的。例如, 若方程为 $dy/dx = ay$, 则 $y|_{x_1} = y|_{x_0}/(1-a\Delta x)$ 。若为方程 (4), 则 (请思考为何只取了二次方程两个实数解中的一个):

$$\xi|_{\tau_1} = \frac{1}{2\Delta\tau} \left\{ -(1 + \varphi\Delta\tau) + [(1 + \varphi\Delta\tau)^2 + 4(\xi|_{\tau_0} + \varphi\Delta\tau)\Delta\tau]^{1/2} \right\}. \quad (15)$$

但一般情况下, 直接求解方程 (14) 是不可能的, 须通过牛顿法反复迭代求解。

牛顿法求解隐函数的计算代价高 (每次矩阵求解的代价皆为 $O(N^2)$, 且须反复求解), 代数方程求解本身的收敛性也会成为问题。一般情况下, 我们仅进行一次牛顿迭代即可, 这样的方法等效于用雅可比矩阵估计 x_1 处的导数值。这时方程 (14) 的近似解为:

$$y_i|_{x=x_1} \simeq y_i|_{x=x_0} + \Delta x (\delta_{ij} - J_{ij}|_{x_0} \Delta x)^{-1} \left[\frac{dy_j}{dx} \right]_{x=x_0}, \quad J_{ij}|_{x_0} \equiv \left[\frac{\partial}{\partial y_j} \left(\frac{dy_i}{dx} \right) \right]_{x=x_0}. \quad (16)$$

式中 $\delta_{ij} \rightarrow \mathbf{I}$ 即为同阶单位矩阵, 倒数意为矩阵逆 (注意, 此处求解的仍是形如 $Ax = b$ 的矩阵问题而非逆矩阵本身, 这比求逆矩阵再乘向量的计算代价低不少)。这样的方法称为半隐式法 (semi-implicit method)。

同样使用 $\Delta\tau \in \{0.4, 0.2, 0.1\}$ 的步长, 我们使用公式 (15) 所示的隐式法与 (16) 所示的半隐式法, 各自对取 $\varphi = 20$ 的方程 (4) 进行求解并与解析解 (公式 5) 进行对比, 结果展示于图 3 中。可见, 尽管在每一时刻皆与理论结果存在差异, 隐式与半隐式方法仍然很好地保证了解的稳定性, 在步长较大的情况下并没有出现如图 2 中显式方法的发散问题。除了公式 (15) 与 (16) 所示的具有一阶精度的单步 (半) 隐式方法, 人们还发展了许多的阶或多步半隐式方法, 以提高数值精度。其中, Rosenbrock 方法具有准四阶精度却每步只需求解一次矩阵, 在提高了精度的同时控制了计算代价, 因而较为受欢迎 (例如, Press et al. 2002 §17.5.1)。

如果方程组的刚性实在过强（如刚性比高达 10^{10} ），常规的半隐式乃至隐式方法也往往力有未逮。这时，在变化速度较慢的模式观点上，变化较快的模式一直处于演化结束后的“稳定”状态。在物理化学中的一个常见的例子是，一组速度极快的反应与其逆反应，与另一组速度较慢的反应通过共同参与两组反应的某化学物质耦合起来——在较慢反应看来，极快的反应与逆反应时常处于化学平衡中。此时，人们往往将极快的反应及其逆反应抽离出来，认为它们确实处于化学平衡，将其对应的微分方程转化为代数方程，再将这个代数方程给出的约束条件代入较慢反应的微分方程中求解。这类“将微分方程化为代数——微分方程求解”的思路，也是刚性问题求解中经常使用的。

1.1.5 容差与自适应步长控制

一般而言，在对常微分方程求解时，每一步的步长越大，该步的误差也会越大，为了减小误差而控制步长是常见的行为。然而，如果在因变量变化趋势较平缓的情况下仍然使用较小的步长，则计算代价将大为增加，而最终结果的准确度并不会大幅提高。是否可以让求解时的步长根据我们对误差的要求自动地随方程的实际状况随时进行调整呢？

欲根据误差需求调整步长，须先对误差进行具体的估计。最常用的方法是所谓的理查德森外推（Richardson extrapolation），即通过不同阶算法相互之间的偏差来估计误差的大小。在实践中，人们经常采用的是所谓“嵌入式”（embedded）理查德森外推，即用高阶方法的中间步骤直接给出低阶的结果，再与高阶方法本身进行对比，借此得出误差估计。如此可以避免使用不同阶方法时的额外计算开销，代价是误差估计的效果略逊于标准的理查德森外推。

最简单的例子是，以 §1.1.2 中陈述的二阶龙格——库塔法为基础，说明此类误差估计的运作方式。我们可使用其中求得的 $\tilde{f}_0$ ，给出比方法本身低一阶（实为欧拉法）的 y_1 的估计；将其与二阶方法对比：

$$\begin{aligned} y_1^{(1)} &= y_0 + \Delta x \tilde{f}_0, \quad y_1^{(2)} = y_0 + \frac{\Delta x}{2} \tilde{f}_0 + \frac{\Delta x}{2} \tilde{f}_1; \\ \epsilon &\sim \left| y_1^{(1)} - y_1^{(2)} \right| = \frac{\Delta x}{2} \left| \tilde{f}_0 - \tilde{f}_1 \right|. \end{aligned} \quad (17)$$

这里的 ϵ 即为估计所得的误差。在实践中，我们须先对积分器提出对误差的容忍上限（“容差”），同时给出绝对容差（记为 atol）和相对容差（记为 rtol）。此时总容差 $\mathcal{T}$ 及对此归一化的相对误差 $\mathcal{E}$ 为：

$$\mathcal{T} = \text{atol} + \text{rtol} \times \max\{|y_0|, |y_1|\}, \quad \mathcal{E} \equiv |\epsilon/\mathcal{T}|. \quad (18)$$

若 $\mathcal{E} > 1$ ，则表明当前步未能满足容差需求，此时一般须抛弃上一步，将原步长乘以一个系数 η ($\eta < 1$ ；常用的表达式为 $\eta = \mathcal{E}^{-1/(s'+1)}$ ，其中 s' 为用于估计 ϵ 时较低阶算法的阶数)，重新进行积分（注意此时若积分成功，则还须补上剩余步长，因此时距当前步原本的终点还差 $(1 - \eta)\Delta x$ ）。若步长乘以 η 后的积分仍然失败，则可递归地减小步长直至成功（或超出层数上限、报错退出）。若 $\mathcal{E} < 1$ ，表明当前步积分成功，接受当前步。同时，下一步的步长可由：

$$(\Delta x)' = \Delta x \min\{\mathcal{E}^{-1/(s'+1)}, \mathcal{S}\}, \quad (19)$$

给出，其中 $\mathcal{S}$ 为一避免步长因 $\mathcal{E}$ 过小而突然扩大过多的安全系数（人们一般经验性地取 $\mathcal{S} = 2$ ）。尽管本小节的方法是针对二阶显式龙格——库塔法举例，但其仍可以相同思路较容易地拓展至更高阶的方法乃至隐式方法。

1.2 从星体结构说起：边值问题

当我们不用考虑星体的许多复杂细节及动态，而只关注其稳态整体性质时，可以认为星体是球对称的，且处于静力平衡。在这一假设下，星体的内部结构满足如下关系：

$$\frac{dM}{dr} = 4\pi r^2 \rho, \quad \frac{dp}{dr} = -\frac{GM\rho}{r^2}. \quad (20)$$

式中，自变量 r 为到星体中心的距离，因变量 M 为半径 r 的球面内星体物质的总质量，而 ρ 和 p 分别为 r 处的物质密度和压强。

以上方程组尚欠缺一部分：物态方程 (equation of state)，其描述了物质的性状之间的相互关系 (特别是压强与密度的关系)，也使得方程组“封闭” (即独立方程数等于独立因变量数)。为了给出物态方程，人们常常认为 p 与 ρ 有一一对应的关系，但这往往是包涵了特定的假设的。例如，当采用所谓的多方物态方程 $p = K\rho^\gamma$ 时，人们一般会假定 K 是常数。若 γ 为比热容比 (“绝热”物态方程)，则 K 反映的是气体比熵 (单位质量的熵值) 的对数 (部分文献直接将其不太严谨地称为比熵)，该方程事实上假定了“整个星体比熵一致”——这一条件是需要星体各处均较为有效地参与对流方能达到的，而等熵条件下 γ 不变则须假定研究对象为理想气体。若 $\gamma = 1$ ，则须假定体系为等温理想气体构成，而这一条件则需要更加严苛的物理机制以保证成立。总之，在对星体进行较为粗糙的建模时，这些假设尚且可行；但若需要精细研究星体内部过程或以此为基础进行推导时，我们不应不加辨别地接受这些假设。

值得指出的是，若采用绝热物态方程 $p = K\rho^\gamma$ ，方程 (20) 可变换为无量纲的标准形式：

$$\frac{d^2\theta}{d\xi^2} + \left(\frac{2}{\xi}\right) \frac{d\theta}{d\xi} + \theta^n = 0, \quad n \equiv \frac{1}{\gamma-1}, \quad \theta \equiv \left(\frac{\rho}{\rho_0}\right)^{1/n}, \quad \xi \equiv r \left[\frac{(n+1)K\rho_0^{1/n-1}}{4\pi G}\right]^{-1/2}, \quad (21)$$

其中 ρ_0 为星体中心物质密度，边界条件为 $\theta_{\xi=0} = 1$ 、 $[d\theta/d\xi]_{\xi=0} = 0$ (后者来自星体中心的非奇异性条件，若导数非零则导致发散)。此即所谓 Lane-Emden 方程，但凡 $n < 5$ 则其在有限的 ξ 处必有零点 (对应星体表面)，且解的情况只与 n (即 γ) 有关、其他参量仅在恢复量纲时有用。典型流程例如，根据星体大致特性推断 γ (因而得出 n)，以 §1.1 中所述方法，按初值问题数值求解方程 (21) 获得无量纲星体质量和表面半径等信息 (对常见的 n 甚至可以直接查表)，再调节 K 的值使得有量纲参量符合观测，最后借此定出星体总质量、内部结构等信息。然而，为了方便向更一般的、无法用 $p = K\rho^\gamma$ 表达物态方程的情形推广，也为了教学目的，我们此处使用另一套稍显繁琐但更具一般性的方法解决。

假设我们通过观测，获取了某个星体的半径 R_0 与质量 M_0 ⁴；现欲知其内部结构，包括密度、压强等关键物理量随半径的变化，怎么做？我们首先须认识到，星体关键参数 (质量、半径等) 是无法反映其内部结构全部信息的，必须做额外的假定 (设想：我们若可以屏蔽所有热交换并可任意调节任意位置的温度，则结构完全无法确定)；此处我们假定其内部仍然满足均匀比熵的条件，则其温度须满足如下关系：

$$\frac{dT}{dr} = \nabla_{\text{ad}} \left(\frac{T}{p}\right) \frac{dp}{dr}, \quad \text{其中: } \nabla_{\text{ad}} \equiv \left(\frac{\partial \ln p}{\partial \ln T}\right)_s. \quad (22)$$

上式采用了恒星物理中常用的记号 ∇_{ad} ，称为“绝热梯度” (adiabatic gradient)，为一无量纲参数而非

⁴对同时具有凌星 (给出半径) 与 RV (宿主恒星视向速度) 或 TTV (多行星系统凌星时变) 数据 (RV 与 TTV 皆可给出质量) 的部分系外行星，这是常见的情形。对少部分恒星而言，其半径可用迈克尔逊测星干涉仪给出。




图 4: 打靶方法的参数求解过程展示 (参见 §1.2.1), 分别展示不同参数 $\{\varpi_0, \kappa\}$ 取值下, $\eta = 1$ 处的 ϖ (左侧) 和 μ (右侧) 数值。右侧图中白色箭头展示了从参数 $\{\varpi_0, \kappa\} = \{1, 1\}$ 以牛顿法迭代逼近最终解的过程。

算符。结合方程 (22), 我们对方程 (20) 进行无量纲化:

$$\begin{aligned} \frac{d\mu}{d\eta} &= 4\pi\eta^2\varrho, \quad \frac{d\varpi}{d\eta} = -\eta^{-2}\mu\varrho, \quad \frac{d\tau}{d\eta} = -\nabla_{\text{ad}}\left(\frac{\tau}{\varpi}\right)\frac{d\varpi}{d\eta}, \\ \text{其中: } \mu &\equiv \frac{M}{M_0}, \quad \eta \equiv \frac{r}{R_0}, \quad \varrho \equiv \frac{\rho}{M_0 R_0^{-3}}, \quad \varpi \equiv \frac{R_0^4 p}{GM_0^2}, \quad \tau \equiv \frac{R_0 k_B T}{GM_0^2}. \end{aligned} \quad (23)$$

此处, 我们终于到了必须采用某种具体的物态方程的时候; 简便起见, 我们采纳理想气体的 $p = K\rho^\gamma$, 令 $\kappa \equiv KG^{-1}M_0^{\gamma-2}R_0^{1+3\gamma}$ 可使我们“绕过”为更一般情况准备的 $d\tau/d\eta$ 方程, 可得到简化的方程:

$$\frac{d\mu}{d\eta} = 4\pi\eta^2 \left(\frac{\varpi}{\kappa}\right)^{1/\gamma}, \quad \frac{d\varpi}{d\eta} = -\eta^{-2}\mu \left(\frac{\varpi}{\kappa}\right)^{1/\gamma}. \quad (24)$$

1.2.1 打靶法: 有的放矢地试错

简化后的方程 (24) 有两个因变量, 须在区间 $\eta \in [0, 1]$ 上求解, 其边界条件为 $\eta = 0$ 处的 $\mu|_{\eta=0} = 0$ 、 $[d\varpi/d\eta]_{\eta=0} = 0$, 以及 $\eta = 1$ 处的 $\mu|_{\eta=1} = 1$ 、 $\varpi|_{\eta=1} = 0$ 。其中, $\eta = 0$ 处的边界条件更多地来自数学上 (因而可认为不可改变), 而 $\eta = 1$ 的两个边界条件表达式是要让方程的解去试图“适配”的。与此同时, 我们也有两个“参数”可以调节, 分别是星体中心 $\eta = 0$ 处的无量纲压强 $\varpi_0 \equiv \varpi|_{\eta=0}$, 以及比熵参数 κ (与中心压强 ϖ_0 结合, 这等效于给定 $\tau|_{\eta=0}$, 所以也可认为是调节星体中心温度)。因为**参数数量与须适配的边界条件数量一致**, 这样的问题是适定的; 当参数数量多于或少于须适配的边界条件数量, 问题会分别成为欠定和超定的。我们一般要避免超定或欠定情形的出现 (若出现, 须先检查是否遗漏了物理量及其相互关系的表达式, 或考虑引入额外的限制或约束条件), 但特殊情况下我们也必须解决非适定问题, 这需要因地制宜地选定解决方案, 此处不展开叙述。

我们首先选取 $\gamma = 5/3$, 对应于该星体全部由单原子分子构成。如何确定参数组 $\{\varpi_0, \kappa\}$ 呢? 我们可将常微分方程组 (24) 从 $\eta = 0$ 到 1 的积分过程视为一次从 $\{\varpi_0, \kappa\}$ 到 $\{\varpi|_{\eta=1}, \mu|_{\eta=1} - 1\}$ 的映射——我们将这一映射记为函数 $f(\varpi_0, \kappa)$, 则求解边值问题即可等效于求解 $f(\varpi_0, \kappa) = \{0, 0\}$ 的二元方程求解问题。一般地, 所有常微分方程边值问题都可归结为多元方程的数值求解问题, 而该方程所对应的函数须由常微分方程 (组) 的数值积分给出。




图 5: 边值问题示例——星体结构常微分方程组 (24) 的求解结果。虚线为 $\{\varpi_0, \kappa\} = \{1, 1\}$ 的初始参数猜测对应的积分结果，而实线为经历数值求解后的 $\{\varpi_0, \kappa\} = \{0.67, 0.44\}$ 对应的积分结果。

继续以方程组 (24) 为例。我们先对参数组 $\{\varpi_0, \kappa\}$ 的取值做一猜测，例如取为 $\{1, 1\}$ 。在此前提下，将方程 (24) 从 $\eta = 0$ 起，按初值问题以四阶龙格——库塔法开始向外积分至 $\eta = 1$ ，观察此处的 $\{\varpi, \mu - 1\}_{\eta=1}$ 是否为 $\{0, 0\}$ 。为了避免遇上 $\varpi < 0$ 的情形（程序可能因无法处理负数的非整数幂或认为负值热力学量无意义，从而给出错误结果），我们对物态方程进行延拓⁵，令 $\rho = \rho(|p|)$ 。第一次尝试几乎一定不能令 $\{\varpi, \mu - 1\}_{\eta=1} = \{0, 0\}$ ，此时我们分别令 ϖ_0 与 κ 先后变动一个小量 $\delta\varpi_0$ 与 $\delta\kappa$ ，求得分别变动后的两组 $\{\varpi, \mu\}_{\eta=1}$ 。这时，我们大致掌握了在当前 $\{\varpi_0, \kappa\}$ 附近， $\{\varpi, \mu - 1\}_{\eta=1}$ 随参数值变动的规律。更具体地说，我们此时可以通过牛顿法，求得下一次应当取为尝试的参数 $\{\varpi'_0, \kappa'\}$ ：

$$\begin{bmatrix} \varpi'_0 \\ \kappa' \end{bmatrix} = \begin{bmatrix} \varpi_0 \\ \kappa \end{bmatrix} - J^{-1} \begin{bmatrix} \varpi_1 \\ \mu_1 - 1 \end{bmatrix}, \text{ 其中雅可比矩阵可估计为: } J \simeq \begin{bmatrix} \delta\varpi_{\eta=1}/\delta\varpi_0 & \delta\varpi_{\eta=1}/\delta\kappa \\ \delta\mu_{\eta=1}/\delta\varpi_0 & \delta\mu_{\eta=1}/\delta\kappa \end{bmatrix}. \quad (25)$$

如是反复迭代，直至收敛到我们希望的准确度。这一求解过程如图 4 所示，而其求解结果如图 5 所示（如果问题较为简单、求解代价较低，我们甚至可以人工观察 $\{\varpi_1, \mu_1\}$ 的变化趋势、手工调整参数的取值）。这样的迭代可能无法收敛，此时我们需要首先检讨最初的参数猜测值是否合理，并更换猜测值，再行尝试。具体到本问题中，通过上述牛顿法迭代得到，

这一方法被命名为“打靶法”（shooting method）。在使用未校准或受到侧风等多种因素干扰的武器打靶时，我们须通过上一发的弹着点，乃至前两发弹着点所给出的“弹着点对修正量的导数”，对下一次射击的参数（所谓“射击诸元”）进行修正——这正是自 18 世纪起炮兵射击时所进行运算的实质⁶。

回忆“数学物理方程”或类似课程、教材，我们会发现，课程或教材中所进行的特殊常微分方程本征函数求解（所谓斯图姆——刘维尔问题），本质上就是此处的问题的特殊情况——给定具有一个参数的常微分方程的边界条件，找到能使得微分方程及其边界条件得以满足的函数及其对应的参数值。只

⁵另一种变通的方案为，并不积分到 $\eta = 1$ 停止，而是积分到星体表面（即 $\varpi = 0$ ），考察此时的 $[\eta_1, \mu_1]$ 的值是否为 $[1, 1]$ 。须注意的是，积分的最后一步往往无法导致 ϖ 严格取零而是使其变为很小的负值；此时请调节最后一步的步长、重试最后一步积分，以使 ϖ 真正为零。

⁶现代武器的火控计算机事实上常常进行与本节所述一致的操作：求解常微分方程的边值问题以确定外弹道，而其边界条件正是“由膛口位置出发”和“命中目标”。




图 6: 雅可比迭代对方程 (26) 的求解过程及结果。

是, 通常的斯图姆——刘维尔问题是线性的, 且需要微分方程算符具有自伴性 (若将微分算符离散化并化为矩阵, 自伴性意味着矩阵是厄米对称的) ——这将导致不同本征值对应的本征函数在给定测度下的斯蒂尔吉斯积分为零 (对应于不同本征值下厄米矩阵的本征向量正交) ——用以构成其所在函数空间的一组完备基。而一般情况下, 非线性的微分方程算符加上非自伴性, 将导致不同参数值对应的函数互不正交 (甚至 “正交” 对非线性问题也难以定义)。这一对比有助于启发我们建立常微分方程组边值问题求解过程及结果的数学图像, 也让以上问题得到了 “广义本征值问题” 的称谓。

1.2.2 松弛法：迭代的魅力

上述的打靶法简明易懂, 在微分方程边值问题的求解中获得了极其广泛的应用。然而, 还有一类称为 “松弛法” (relaxation method) 的方法同样获得了极其广泛的应用。本节拟对松弛法的基本原理做一简要介绍, 这些介绍也对本课程晚些时候的 “椭圆型偏微分方程求解” 内容有直接引导意义。

为简单起见, 我们从一个与星体结构暂时无关 (但与天体物理其他方面关系极其密切, 如牛顿引力场的求解) 的二阶常微分方程开始, 且不对其进行降阶处理:

$$\frac{d^2 u}{dx^2} = -v(x), \quad u|_{x=-1} = u|_{x=1} = 0, \quad v(x) = \Theta(0.25 - |x|) \quad (26)$$

这是一个定义在 $[0, 1]$ 区间上的一维泊松方程, $v(x)$ 为一与 u 不相关的场源项 (其中 Θ 当参数为正时取 1, 否则为 0); 其求解当然可以通过打靶法进行, 然而我们将采取另一种方案。首先在区间 $[0, 1]$ (含端点) 均匀地放上 $(N+1)$ 个点, 将区间分成 N 个长度为 $1/N$ 的小段; 在每个点上, 坐标 x 的值为 $x_n = n/N$, 两个相邻点相距为 $\Delta x = 1/N$ 。在除了 $n=0$ 或 N 的各个点上, 离散化的 u 的取值应当满足 (由二阶中心差商近似给出二阶导数):

$$\frac{2u_n - u_{n+1} - u_{n-1}}{\Delta x^2} = v(x_n). \quad (27)$$

雅可比迭代

人们发现, 这样以离散格式书写的微分方程, 稍经调整后可以给出一个用以求解方程的递推关系:

$$u'_n = \frac{u_{n+1} + u_{n-1} + v(x_n)\Delta x^2}{2}. \quad (28)$$

其中, 带撇的 u'_n 代表更新后的离散化近似解, 不带撇的 u_{n+1} 和 u_{n-1} 代表更新前的值, 而 $v(x_n)$ 的值不受更新影响。这一做法被称为**雅可比迭代** (Jacobi iteration): 先给定离散化的 u 的最初猜测值 (对方程(26) 而言可以令初始时所有 $u_n = 0$), 借助公式 (32) 反复迭代, 次数足够多之后便可以得到相当好的 u 的数值近似解 (如图 6 所示)。这一方法向二维、三维泊松方程的推广也是非常容易的, 只须将表达式 (27) 和 (32) 对应地改为二维和三维下的形式即可。

迭代法的数学基础

为什么这样看似简单粗暴的方式竟然能够有效呢? 我们发现, 如果将 $\{u_n\}$ 视为一个向量, 则方程 (27) 可以表达为一个“矩阵乘向量”的形式:

$$\begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & 2 & -1 & \\ & & & \ddots & \\ & & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} \begin{bmatrix} u_0 (= 0) \\ u_1 \\ u_2 \\ \vdots \\ u_{N-1} \\ u_N (= 0) \end{bmatrix} = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_{N-1} \\ b_N \end{bmatrix}, \quad (29)$$

其中 $b_n \equiv v(x_n)\Delta x^2$ 。我们将其简记为 $Au = b$, 并称 A 为二阶导数离散化后的算符的矩阵表示。同时, 我们注意到 $A = D + U + L$, 其中:

$$U \equiv \begin{bmatrix} 0 & -1 & & & \\ & 0 & -1 & & \\ & & 0 & -1 & \\ & & & \ddots & \\ & & & & 0 & -1 \\ & & & & & 0 \end{bmatrix}, \quad L \equiv U^T, \quad D = 2I, \quad (30)$$

分别为 A 的上三角、下三角、对角部分。记 $R \equiv -D^{-1}(U + L)$, $Au = b$ 可改写为:

$$(D + U + L)u = b \Rightarrow Du = -(U + L)u + b \Rightarrow u = Ru + D^{-1}b. \quad (31)$$

我们记 u 为方程 (29) 的真正解, 而 $\tilde{u}^{(m)}$ 为经历 m 次迭代后 u 的近似值, 并记 $e^{(m)} \equiv \tilde{u}^{(m)} - u$ 为 m 次迭代后的残差, 则公式 (32) 所描述的迭代及其对残差的影响可记为 (结合公式 31):

$$\tilde{u}^{(m)} = R\tilde{u}^{(m-1)} + D^{-1}b \Rightarrow e^{(m)} = R e^{(m-1)} = R^m e^{(0)}. \quad (32)$$

不难验证, 当 $m \rightarrow \infty$, $R^m \rightarrow 0$ 。这一结论的数学基础如下: 可证明矩阵 R 的第 j 个本征值为 $\lambda_j = 1 - 2\sin^2(j\pi/2n)$, 并记其本征值分解为 $R = \Lambda^T \text{diag}(\lambda_0, \dots, \lambda_N) \Lambda$ (因 R 为实对称矩阵, 其不同特征值对应的特征向量相互正交, $\Lambda^T \Lambda = \mathbf{I}$), 则 R 的 m 次幂可表示为:

$$\begin{aligned} R^m &= \Lambda^T \text{diag}(\lambda_0, \dots, \lambda_N) \Lambda \Lambda^T \text{diag}(\lambda_0, \dots, \lambda_N) \Lambda \cdots \Lambda^T \text{diag}(\lambda_0, \dots, \lambda_N) \Lambda \\ &= \Lambda^T \text{diag}(\lambda_0^m, \dots, \lambda_N^m) \Lambda, \end{aligned} \quad (33)$$

进而, 对迭代后的残差, 有:

$$|e^{(m)}| = |R^m e| = [e^T (R^m)^T R^m e]^{1/2} = [e^T \Lambda^T \text{diag}(\lambda_0^{2m}, \dots, \lambda_N^{2m}) \Lambda e]^{1/2} \leq |e| [\max\{|\lambda_j^{2m}|\}]^{1/2}. \quad (34)$$




图 7: 高斯—赛德尔迭代对方程 (26) 的求解过程及结果。

因为对各本征值皆有 $|\lambda_j| < 1$, 所以当迭代次数足够多, $|e^{(m)}|$ 将渐趋于零。这就意味着, 经历足够多次的迭代, 残差将趋于零, 而 $\tilde{u}^{(m)}$ 将与 u 越来越接近。更一般地, 只要原本的离散微分算符表示成的矩阵 A 的对角元的绝对值大于非对角元 (此时称 A 为“对角占优矩阵”), 上面的论证就依然成立。

在实际操作中, 上述操作不仅适用于类似于 (26) 所示的泊松方程, 还可适用于含有非齐次项的亥姆霍茨方程 ($d^2u/dx^2 + ku = v$), 甚至一定程度上适用于准线性的方程 $d^2u/dx^2 + f(u) = v$ (其中 $f(u)$ 可以为 u 的非线性函数) ——在离散化后的方程 (32) 中, 此时 $f(u)$ 一般以更新前的值、以源项的方式, 与 $v(x)$ 一起出现。总之, 只离散化微分算符 A 仍为对角占优, 即可使用上述的方法迭代求解。

“松弛法”名称的由来

松弛法的名称来自于此算法的物理图像。观察公式 (32) 可以发现, 若不考虑源项 v , 则 u_n 为 u_{n+1} 与 u_{n-1} 两点处 u 数值的平均。考虑一根弹性很好的薄塑料条, 其上某处的内部应力正比于此处曲率, 也即正比于其形态的二阶导数。当该点处的应力最小化 (“松弛”) 时, 该点附近应尽可能 “伸直”, 此时该点的位置即为相邻点的平均值。若对其加上一定的外部力 (即为源项 v), 塑料条的形态会在其内部张力与外部驱动力的联合作用下平衡, 而靠近平衡的过程事实上便是进行公式 (32) 中的迭代, 每次迭代即是条上某点趋近其平衡位置的过程, 也即是整个塑料条内部额外应力渐渐释放、整体渐渐松弛、能量趋于最小的过程⁷——用泛函分析的语言表述, 若认为该塑料条在 x 处的形变为 u 而其剪切弹性系数为 2, 则松弛法正是在最小化其整体能量泛函: $E = J[u] \equiv \int dx (d^2u dx^2 - v)$ 。这意味着我们可以使用变分法解决问题, 而 “逐点定义函数值” 的变分法正是本课程早些时候的有限单元 (“有限元”) 方法。

高斯—赛德尔迭代

雅可比迭代简明易懂, 但实践中却很少使用。在公式 (32) 中, 用于生成新的 u'_n 的数据, 全部为上一步迭代中的数据; 为了不破坏这一条件, u'_n 必须新的数据空间中存放, 这导致存放数据的空间须为有效数据的两倍。历史上, 有人做出尝试: 当对 u 进行从 $n = 0$ 至 $n = N$ 的更新时, 不理睬 “部

⁷历史上 (现代计算机发明前), 当工程设计人员需要依照给定的多个点绘制一条相对复杂的曲线时, 往往会在图板上给定点两侧各打一个大头针, 每对大头针之间形成一个窄缝 (用以对其中的物体给予约束, 或者说给予外界力), 再让一根薄而弹性好的光滑木条从每一个窄缝中穿过; 随后稍稍拍动图板或来回抽拉木条, 使木条内部的紧张度基本消除 (即是在约束下最小化木条弹性能的过程), 最后用铅笔或描图笔沿着木条将该曲线绘制出来。此时该薄木条常被称为 “样条”, 这也是数值分析中 “样条插值” 一词的由来。

分数据已更新”的事实，直接使用部分更新、部分未更新的数据。对应于公式 (32)，这一方法可写为：

$$u'_n = \frac{u_{n+1} + u'_{n-1} + v(x_n)\Delta x^2}{2}, \quad (35)$$

这样便省下了用于存放上一步结果的空间。经实践发现，这种做法竟然产生出了比雅可比迭代更快、更好的收敛性。为什么呢？沿用前面的记号，我们发现，这种迭代方式可以写作：

$$\begin{bmatrix} 2 & & & & \\ -1 & 2 & & & \\ & -1 & 2 & & \\ & & & \ddots & \\ & & & -1 & 2 \\ & & & & 2 \end{bmatrix} \begin{bmatrix} \tilde{u}_0^{(m)} \\ \tilde{u}_1^{(m)} \\ \tilde{u}_2^{(m)} \\ \vdots \\ \tilde{u}_{N-1}^{(m)} \\ \tilde{u}_N^{(m)} \end{bmatrix} = \begin{bmatrix} 0 & -1 & & & \\ & 0 & -1 & & \\ & & 0 & -1 & \\ & & & \ddots & \\ & & & & 0 & -1 \\ & & & & & 0 \end{bmatrix} \begin{bmatrix} \tilde{u}_0^{(m-1)} \\ \tilde{u}_1^{(m-1)} \\ \tilde{u}_2^{(m-1)} \\ \vdots \\ \tilde{u}_{N-1}^{(m-1)} \\ \tilde{u}_N^{(m-1)} \end{bmatrix} + \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_{N-1} \\ b_N \end{bmatrix}, \quad (36)$$

也即， $(D + L)\tilde{u}^{(m)} = U\tilde{u}^{(m-1)} + b$ 。记 $R_G \equiv (D + L)^{-1}U$ ，则相应的迭代处理及其对残差影响可记为：

$$\tilde{u}^{(m)} = R_G \tilde{u}^{(m-1)} + (D + L)^{-1}b \Rightarrow e^{(m)} = R_G e^{(m-1)} = R_G^m e^{(0)}, \quad (37)$$

可见对残差的影响与雅可比迭代的公式(32)形式上一致，只是代表迭代的松弛矩阵不同。分析松弛矩阵 R_G ，可发现其特征值的绝对值也不超过 $1 - 2\sin^2(\pi/2N)$ （松弛矩阵特征值的最大绝对值一般称为“谱半径”），且均小于雅可比松弛矩阵的所有特征值的模，因而其收敛速度快于雅可比迭代。这一方法称为**高斯—赛德尔迭代**（Gauss-Seidel iteration，简称 GS），是当今松弛法解此类问题的标准方法之一（如图 7 所示）。类似地，还有更适合共享内存模型或 GPU 等类向量处理器执行并行运算的“红黑高斯——赛德尔迭代”（将求解区域如国际象棋棋盘一般着为红色与黑色，偶数轮只求解红色区域，奇数轮只求解黑色区域），也可用类似的方法进行分析。原则上，一阶问题也可使用松弛法求解；然而，不难证明，对一阶问题使用松弛法，若不能对方程方便地“升阶”（或恢复二阶），其实质基本是与打靶法等效的，故此处并不单独讨论。

正如前文提到的，本小节所述的方法可以比较容易地拓展至高维的情况。在本课程的稍后部分、讲述椭圆型偏微分方程的求解时，我们会再次遇到此类方法；但那时，我们就要以对此类方法的另一种重大改进（多重网格方法）为主要目标了。

1.3 守恒第一：星体轨道的积分

常微分方程单元的最后一块拼图，来自于最“原汁原味”的天体物理模拟、至今天体物理研究中仍经常遇到的问题：星体轨道的积分。星体在引力场 $\{g_i\}$ 运动所满足的微分方程，形式上是相当简单的：

$$\frac{d^2 x_i}{dt^2} = g_i = -\partial_i \Phi. \quad \left(\partial_i \equiv \frac{\partial}{\partial x_i} \rightarrow \nabla \right) \quad (38)$$

其中 Φ 为引力势。在计算由大量星体构成的体系时， Φ 的计算是颇有一些值得探讨的技术和技巧的，这将在本课程的晚些时候提及。本部分只考虑最简单的情况——不动的点状引力场源，即 $\Phi = -GM/|\mathbf{x}|$ （即所谓开普勒问题），以此突出星体轨道积分问题本身。

将点源引力势代入方程 (38)，经无量纲化可得，

$$\dot{\mathbf{q}} = \mathbf{p}, \quad \dot{\mathbf{p}} = -\frac{\mathbf{q}}{|\mathbf{q}|^3}; \quad \mathbf{q} \equiv \frac{\mathbf{x}}{x_0}, \quad \mathbf{p} \equiv \left(\frac{x_0}{GM} \right)^{1/2} \frac{d\mathbf{x}}{dt}, \quad \cdot \equiv \frac{d}{d\tau}, \quad \tau \equiv \left(\frac{GM}{x_0^3} \right)^{1/2} t. \quad (39)$$

此处 x_0 为初始时刻星体距引力点源距离。我们应用了公式 (2) 所示的“降阶”技巧（而 $\mathbf{p}$ 本身又有无量纲正则动量的物理意义，与无量纲坐标一同构成一组正则共轭变量 $[\mathbf{q}, \mathbf{p}]$ ）。容易验证，方程 (39) 有多个运动积分（守恒量），包括：

$$\epsilon \equiv \frac{\mathbf{p}^2}{2} - |\mathbf{q}|^{-1} \text{ (能量)} , \quad \mathcal{L} \equiv \mathbf{q} \times \mathbf{p} \text{ (角动量)} , \quad \mathcal{A} = \mathbf{p} \times \mathcal{L} - \frac{\mathbf{q}}{|\mathbf{q}|} \text{ (龙格——楞次矢量)} . \quad (40)$$

在上述无量纲化的框架下，龙格——楞次矢量的模等于轨道偏心率 e 。可以证明，开普勒问题的角动量与能量并不独立，能量可以表达为角动量的齐次函数（即表达式中只有 $\mathcal{L}$ 而无其他变量）。

我们将 $\tau = 0$ 时刻的初始条件设为 $\mathbf{q} = [1, 0, 0]$ 与 $\mathbf{p} = [0, 1.3, 0]$ 或 $[0, 0.4, 0]$ （考虑到系统的对称性，可以不考虑 q_z 、 p_z 的变化），以 $\Delta\tau = 10^{-2}$ 为步长，分别选用正、反向欧拉法和四阶龙格——库塔法，将系统积分至 $\tau = 10^2$ ——星体轨迹随时间的演化状况如图 8 所示。可以发现，包括隐式方法在内，两种方法都未能很好地保持运动积分的守恒性。

1.3.1 什么才是关键？

使用极短的时间步长减小积分误差显然不是理想的办法。我们是否有从“根本”上解决守恒律被破坏的问题呢？数学家和应用数学家们对这一问题进行了深入的研究，其中最为人知的之一是冯康先生在这一方面的工作⁸；我们在此不展开论述，仅就其基本图像做一浅显说明。方程 (39) 事实上是更一般的哈密顿方程的特殊形态，后者一般表述为：

$$\partial_\tau q_i = \frac{\partial H}{\partial p_i} , \quad \partial_\tau p_i = -\frac{\partial H}{\partial q_i} ; \quad \left(\partial_\tau \equiv \frac{d}{d\tau} \right) \quad (41)$$

式中 H 为哈密顿量，可以理解为系统的能量关于 p 和 q 的函数，其表达方式蕴含了动力学系统的一切信息——将公式(40)中的能量表达式（正好仅含有 $\mathbf{q}$ 和 $\mathbf{p}$ ）代入方程 (41) 则可得方程 (39)。

保持守恒的辛条件

若要保持计算过程中的动力系统的守恒律，前提条件是保持哈密顿量不受影响。更具体地说，将 $[\mathbf{q}, \mathbf{p}]$ 进行一步时间演化之后的结果记为 $[\mathbf{q}', \mathbf{p}']$ ，则该映射对 $[\mathbf{q}, \mathbf{p}]$ 的导数 M （可视为其雅可比矩阵）应当满足所谓的辛条件（“辛”音译自 symplectic），即：

$$M \equiv \begin{bmatrix} \partial \mathbf{q}' / \partial \mathbf{q} & \partial \mathbf{q}' / \partial \mathbf{p} \\ \partial \mathbf{p}' / \partial \mathbf{q} & \partial \mathbf{p}' / \partial \mathbf{p} \end{bmatrix} \text{ 应使得: } M^T E M = E , \text{ 其中“单位辛矩阵”: } E \equiv \begin{bmatrix} 0 & \mathbf{I} \\ -\mathbf{I} & 0 \end{bmatrix} . \quad (42)$$

不论是否计划通晓下面两个小节的内容，我们都至少应该记住：星体轨道积分的算法必须是带“辛”的。

选讲：辛条件的证明

为何公式 42 可以成为求解方法能否守恒的判据呢？我们再来观察哈密顿方程。借助单位辛矩阵 E ，哈密顿方程可以写成如下形式：

$$\frac{d}{d\tau} \begin{bmatrix} \mathbf{q} \\ \mathbf{p} \end{bmatrix} = E \begin{bmatrix} \partial H(\mathbf{q}, \mathbf{p}) \\ \partial(\mathbf{q}, \mathbf{p}) \end{bmatrix} . \quad (43)$$

⁸他曾论述道：“在遥远的未来，太阳系呈现什么景象？行星将在什么轨道上运行？地球会与其他星球相撞吗？有人认为，只要利用牛顿定律，按现有方法编个程序，用超级计算机进行计算，花费足够多的时间，便可得到要求的答案。但真能得到答案吗？得到的答案可信吗？实际上对这样复杂的计算，计算机往往得不出结果，或者得出完全错误的结果。每一步极小的误差积累可能会使计算结果面目全非！这是计算方法问题，机器和程序员都无能为力”，并进一步指出：“一切解哈密顿方程的‘正确’的离散算法都应该是辛变换的”。后他因此方面的工作被追授 1997 年国家自然科学一等奖。偏微分方程部分还将简单阐述他的另一项伟大成就：有限单元法（finite element method，简称有限元或 FEM）。




图 8: 对方程 (39) 求解结果, 展示当 $q_0 = [1, 0, 0]$ 时 $p_0 = [0, 1.3, 0]$ (左图) 与 $p_0 = [0, 0.4, 0]$ (右图) 的初始条件下不同方法 (欧拉、反向欧拉、四阶龙格—库塔) 以 $\Delta\tau = 10^{-2}$ 进行轨道积分的结果。

若我们简记正则共轭变量 $[\mathbf{q}, \mathbf{p}]$ 所处所在的时间点为 0, 演化后的 $[\mathbf{q}', \mathbf{p}']$ 所处所在的时间点为 τ (因而带上了时间参数 τ), 则映射 $[\mathbf{q}, \mathbf{p}] \rightarrow [\mathbf{q}', \mathbf{p}']$ (符合哈密顿方程的此种映射也称为“哈密顿流”) 的雅可比矩阵 $M \equiv \partial(\mathbf{q}', \mathbf{p}') / \partial(\mathbf{q}, \mathbf{p})$ (参见公式 42) 也应当带上参数 τ 。如果 $[\mathbf{q}, \mathbf{p}] \rightarrow [\mathbf{q}', \mathbf{p}']$ 的演化满足哈密顿方程, 那么:

$$\begin{aligned}
 \frac{d}{d\tau} [M(\tau)^T E M(\tau)] &= \left\{ \frac{d}{d\tau} \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right]^T \right\} E \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right] + \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right]^T E \left\{ \frac{d}{d\tau} \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right] \right\} \\
 &= \left\{ \frac{\partial}{\partial(\mathbf{q}, \mathbf{p})} \frac{d}{d\tau} \begin{bmatrix} \mathbf{q}' \\ \mathbf{p}' \end{bmatrix} \right\}^T E \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right] + \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right]^T E \left\{ \frac{\partial}{\partial(\mathbf{q}, \mathbf{p})} \frac{d}{d\tau} \begin{bmatrix} \mathbf{q}' \\ \mathbf{p}' \end{bmatrix} \right\} \quad (44) \\
 &= \left[\frac{\partial^2 H(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p}) \partial(\mathbf{q}', \mathbf{p}')} \right]^T E^T E \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right] + \left[\frac{\partial(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p})} \right]^T E^2 \left[\frac{\partial^2 H(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p}) \partial(\mathbf{q}', \mathbf{p}')} \right] \\
 &= \left[\frac{\partial^2 H(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p}) \partial(\mathbf{q}, \mathbf{p})} \right]^T - \left[\frac{\partial^2 H(\mathbf{q}', \mathbf{p}')}{\partial(\mathbf{q}, \mathbf{p}) \partial(\mathbf{q}, \mathbf{p})} \right] = 0.
 \end{aligned}$$

推导中, 第二个等号处认为对 $\partial/\partial(\mathbf{q}', \mathbf{p}')$ 与 $d/d\tau$ 两个求导可交换, 第三个等号处运用了公式 (43) 表达的哈密顿方程, 第四个等号处利用了 $E^T = -E$ 及 $E^T E = \mathbf{I}$ 的简单关系并利用了求导的链式法则 (注意二阶导数的孰前孰后), 第五个等号处利用了海塞矩阵 $\partial^2 H(\mathbf{q}', \mathbf{p}') / \partial(\mathbf{q}, \mathbf{p})^2$ 的对称性质。

若认为以上推导难以读懂, 特别是“对向量的求导”令人迷惑, 则我们更换为张量标记并采用爱因斯坦求和约定, 并如下进行简记: 记相空间坐标 $[\mathbf{q}, \mathbf{p}]$ 为 z_i , 记相空间梯度 $\partial/\partial(\mathbf{q}, \mathbf{p})$ 为 $\partial/\partial z_i \rightarrow \partial_i$ (而 $\partial/\partial(\mathbf{q}', \mathbf{p}')$ 记为 ∂'_i), 记时间导数 $d/d\tau$ 为 ∂_τ , 则我们可将 z'_i 处的哈密顿方程重写为 $\partial_\tau z'_i = E_{ij} \partial'_j H'$,




图 9: 几何图样在相空间中演化的示例。图形虽遭遇扭曲变形, 但面积不变。

而雅可比矩阵可写为 $M_{ij} \equiv \partial z'_i / \partial z_j \equiv \partial_j z'_i$ 。然后, 我们重新进行推导:

$$\begin{aligned}
 \partial_\tau M_{ki} E_{kl} M_{lj} &= (\partial_\tau \partial_i z'_k) E_{kl} (\partial_j z'_l) + (\partial_i z'_k) E_{kl} (\partial_\tau \partial_j z'_l) \\
 &= (\partial_i E_{km} \partial'_m H') E_{kl} (\partial_j z'_l) + (\partial_i z'_k) E_{kl} (\partial_j E_{lm} \partial'_m H') \\
 &= E_{km} E_{kl} (\partial_i \partial'_m H') (\partial_j z'_l) + E_{kl} E_{lm} (\partial_j \partial'_m H') (\partial_i z'_k) \\
 &= \delta_{ml} (\partial_i \partial'_m H') (\partial_j z'_l) - \delta_{km} (\partial_j \partial'_m H') (\partial_i z'_k) \\
 &= (\partial_i \partial'_m H') (\partial_j z'_m) - (\partial_j \partial'_m H') (\partial_i z'_m) \\
 &= \partial_i \partial_j H' - \partial_j \partial_i H' = 0.
 \end{aligned} \tag{45}$$

其中, 各处皆认为求导顺序可交换, 第二个等号处使用了以 z' 为相空间坐标的哈密顿方程, 第四个等号使用了 $E_{ij} E_{jk} = -\delta_{ik}$ (等效于 $E^2 = -\mathbf{I}$, 而 δ_{ik} 为克朗内克的 δ 符号, 等效于单位矩阵, 在张量记号下具有“替换指标”的作用) 及 $E_{ij} = -E_{ji}$ (单位辛矩阵的反称性), 第五个等号处使用了 $(\partial_i z'_j) \partial'_j = \partial_i$ (等效于 $(\partial z' / \partial z)(\partial / \partial z') = (\partial / \partial z)$, 即求导的“链式法则”)。

不论是公式 (44) 还是 (45), 都向我们证明了一个结论: 若系统按照哈密顿方程演化, 则演化任意时间 τ 后, 对于将演化前相空间坐标 $[\mathbf{q}, \mathbf{p}]$ 映射到演化后相空间坐标 $[\mathbf{q}', \mathbf{p}']$ 的映射的雅可比矩阵 M , $M^T E M$ 都不随时间改变。考虑到 $\tau = 0$ 时 M 是单位矩阵, 故 $M^T E M = E$ 对任何服从哈密顿方程 (从而保持应有守恒律) 的动力学系统都应成立——这正是公式 (42) 所说的辛条件。

选讲: 辛条件的数学图像

更有意思的是, 上文看上去抽象的推导, 其结论却有着鲜明的数学图像。我们从理解单位辛矩阵 E 的意义开始。在一个二维欧几里得空间中, 我们对两个向量 $\mathbf{x}$ 和 $\mathbf{x}'$ 关于矩阵 E 构造二次型:

$$\mathbf{x}^T E \mathbf{x}' \equiv [x_0, x_1] \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} x'_0 \\ x'_1 \end{bmatrix} = x_0 x'_1 - x_1 x'_0, \tag{46}$$

而这正是 $\mathbf{x}$ 与 $\mathbf{x}'$ 两个二维向量所“张成”的平行四边形的有向面积 (符号可按右手定则给出)⁹。我

⁹ 不难发现, 这个结果其实对应着 $\mathbf{x} \times \mathbf{x}'$ 。类似地, 三维欧几里得空间中的 $\mathbf{a} \cdot (\mathbf{b} \times \mathbf{c})$ 给出了这三个矢量所张成的平行六面体的有向体积。这

们完全可以把这个定义拓展至高维，将 $2n$ 维的 $\mathbf{x}^T E \mathbf{x}'$ 定义为某种广义有向面积（事实上更常用的提法是“辛内积”），记作 $\langle \mathbf{x}, \mathbf{x}' \rangle$ ；它与常规定义内积的不同几乎仅仅在于其关于 $\mathbf{x}$ 与 $\mathbf{x}'$ 是反对称的，即 $\langle \mathbf{x}', \mathbf{x} \rangle = -\langle \mathbf{x}, \mathbf{x}' \rangle$ 。当对这些 $2n$ 维向量以矩阵 M 进行线性变换时，如果 $M^T E M = E$ ，则 M 显然将使得任意两个向量构成的超平行多面体的广义面积（辛内积）保持不变（请自行验证）。我们称满足 $M^T E M = E$ 的线性变换（矩阵） M 为**辛变换**（辛矩阵）。

回到动力学体系的相空间。假设在初始时刻，在相空间广义坐标 $\mathbf{z} \equiv [\mathbf{q}, \mathbf{p}]$ 附近有一微小的“超面积元”，由两个微小向量 $\delta \mathbf{z} \equiv [\delta \mathbf{q}, \delta \mathbf{p}]$ 与 $\delta \tilde{\mathbf{z}} \equiv [\delta \tilde{\mathbf{q}}, \delta \tilde{\mathbf{p}}]$ 所张成。由上述论断及推广可知，这个小面元的有向广义面积为 $\delta \mathbf{z}^T E \delta \tilde{\mathbf{z}}$ 。在经历动力学演化后，这个面积元移动到了 $\mathbf{z}' \equiv [\mathbf{q}', \mathbf{p}']$ 附近，则两个微小向量会成为 $M \delta \mathbf{z}$ 与 $M \delta \tilde{\mathbf{z}}$ （而 $M \equiv \partial \mathbf{z}' / \partial \mathbf{z} \equiv \partial(\mathbf{q}', \mathbf{p}') / \partial(\mathbf{q}, \mathbf{p})$ 为雅可比矩阵），它们张成的面积就成为 $(M \delta \mathbf{z})^T E (M \delta \tilde{\mathbf{z}}) = \delta \mathbf{z}^T (M^T E M) \delta \tilde{\mathbf{z}}$ 。如果系统演化遵照哈密顿方程，则因 $M^T E M = E$ ，故演化前后其广义有向面积是维持不变的。也即，若在相空间中放入一个小“包裹”，经历哈密顿方程给定的演化，其外形可能会经历拉伸、扭曲等各种变换，但这个“包裹”的广义表面积一定维持不变（示例见图 9）。这个结论也常常被称作“刘维尔定理”，是许多重要的数学及理论物理结论的基础。

小结

我们将前面的陈述总结如下。星体轨道演化的数值算法的职责，便是在每一步演化中将步骤开始时的 $[\mathbf{q}, \mathbf{p}]$ 映射为步骤结束时的 $[\mathbf{q}', \mathbf{p}']$ 。如果这一映射要与哈密顿方程相容，则该映射的雅可比矩阵 M 必须满足辛条件 $M^T E M = E$ （公式 42）。由于系统的动力学演化完全由哈密顿方程（在当前语境中等效于牛顿运动方程）所决定，而哈密顿方程一定会使演化到任意时刻的系统的广义坐标与原始广义坐标之间满足辛条件，则若某算法给出的 M 矩阵违背了辛判据，它就一定会把系统导向不符合哈密顿方程的方向，进而破坏守恒律。换言之，“符合辛判据”是某算法保证哈密顿量（能量）守恒的必要条件——此时该算法属于一种“辛算法”。值得指出的是，这样的判据不仅对星体轨道演化算法有效，也对任何有守恒要求且可用哈密顿方程描述演化过程的科学和工程算法有效。这种从守恒格式出发设计算法的思想，是现代化计算天体物理乃至整个计算物理和应用数学庞大领域的根基。

1.3.2 最简单实用的辛方法

我们首先考察一阶显式欧拉方法，求出其“步进”操作的雅可比矩阵：

$$\mathbf{q}' = \mathbf{q} + \Delta \tau \mathbf{p}, \mathbf{p}' = \mathbf{p} - \Delta \tau \frac{\partial \phi(\mathbf{q})}{\partial \mathbf{q}} \rightarrow M = \begin{bmatrix} \mathbf{I} & \Delta \tau \\ -\Delta \tau \frac{\partial^2 \phi(\mathbf{q})}{\partial \mathbf{q}^2} & \mathbf{I} \end{bmatrix}, \quad (47)$$

此处为了一般性，我们用 $\phi(\mathbf{q})$ 代表势函数，而 $\partial/\partial \mathbf{q}$ 为计算其在 $\mathbf{q}$ 位置的梯度。很容易验证，这样的雅可比矩阵 M 无法满足公式 (42) 给出的辛条件，无怪乎本节开头处的显式欧拉法未能给出合理的轨道数值解。但我们只须稍加改动，在计算下一步正则动量 $\mathbf{p}'$ 时使用已经得到的、下一步的 $\mathbf{q}'$ （而非当前步的 $\mathbf{q}$ ），就能获得极大改进：

$$\mathbf{q}' = \mathbf{q} + \Delta \tau \mathbf{p}, \mathbf{p}' = \mathbf{p} - \Delta \tau \frac{\partial \phi(\mathbf{q}')}{\partial \mathbf{q}'} \rightarrow M = \begin{bmatrix} \mathbf{I} & \Delta \tau \\ -\Delta \tau \frac{\partial^2 \phi(\mathbf{q}')}{\partial \mathbf{q}'^2} & \mathbf{I} - \Delta \tau^2 \frac{\partial^2 \phi(\mathbf{q}')}{\partial \mathbf{q}'^2} \end{bmatrix}, \quad (48)$$

同样容易验证，这样的 M 能使 $M^T E M = E$ 条件得到满足。一般地，只要势函数不依赖于正则动量 $\mathbf{p}$ （这对牛顿引力几乎总是成立），则这样的方法——用新的 $\mathbf{q}'$ （而非旧的 $\mathbf{q}$ ）计算新的 $\mathbf{p}'$ ——总是能

个结论很有用，也有着深刻的数学背景（对应于微分形式在相应流形上的积分测度，任意维数皆然）。我们此处探讨的空间一定是偶数维的，故只用二维欧几里得空间举例，但深入理解辛方法所涉及的知识是现代微分几何，这远不限于二维或偶数维。




图 10: 以辛方法对方程 (39) 求解结果 (初始条件 $q_0 = [1, 0, 0]$, $p_0 = [0, 0.4, 0]$)。左图显示 kick-drift 方法与蛙跳法所得的轨道, 右图显示不同方法下能量相对误差的演化。

使辛判据得到满足。这种最简单的、满足辛条件的算法, 被称为辛欧拉法 (symplectic Euler method)。而在天体物理与天体力学领域, 它被更形象地称为 “**kick-drift**” 方法: 星体仿佛先受到了一次突然的冲击、到达了新位置 $\mathbf{q}'$ (所谓 “kick”), 再从这个新位置开始因为引力势的作用改变其运动状态 (所谓 “drift”)。相应地, “drift-kick” 方法——先计算新一步的 $\mathbf{p}'$, 再用新的 $\mathbf{p}'$ (而非旧的 $\mathbf{p}$) 计算新的 $\mathbf{q}'$ ——也可满足辛条件, 属于另一种辛欧拉法; 相关证明仍很简易, 留作练习。

稍微复杂一些但精度更高的算法被称为**蛙跳** (leapfrog) 方法, 它使用了 “中间步” 的正则坐标 $\tilde{\mathbf{q}}$:

$$\tilde{\mathbf{q}} = \mathbf{q} + \frac{\Delta\tau\mathbf{p}}{2}; \quad \mathbf{p}' = \mathbf{p} - \Delta\tau \frac{\partial\phi(\tilde{\mathbf{q}})}{\partial\tilde{\mathbf{q}}}, \quad \mathbf{q}' = \tilde{\mathbf{q}} + \frac{\Delta\tau\mathbf{p}'}{2}. \quad (49)$$

该方法满足辛条件的证明同样不难, 留作练习。通过对比 kick-drift 方法可以发现, 蛙跳法其实是 kick-drift-kick 方法, 只是前后两次 kick 的步长均为总步长的一半。如果保证步长一致, 则上一步中 $\mathbf{q} \rightarrow \mathbf{q}'$ 的推进可直接与下一步中 $\mathbf{q} \rightarrow \tilde{\mathbf{q}}$ 的推进合并; 此时 $\mathbf{q}$ 与 $\mathbf{p}$ 的推进过程相差半步、相互 “跃过”, 形如两只青蛙交替跃过彼此前进, 故此得名。类似地, 将 “中间步” 取在 $\mathbf{p}$ 上的 drift-kick-drift 方法也可被称为蛙跳法; 该方法同样满足辛条件, 但因为每步须求两次势场梯度而较少采用 (很多情况下, 求势场梯度是需要一定计算开销的)。蛙跳法还具有一个更优越的性质——时间反演对称性: 若给定步长 $\Delta\tau$ 和势函数 ϕ , 当蛙跳法把 $[\mathbf{q}, \mathbf{p}]$ “推进” 至 $[\mathbf{q}', \mathbf{p}']$, 它也会用完全相同的办法把 $[\mathbf{q}', -\mathbf{p}']$ “拉回” 至 $[\mathbf{q}, -\mathbf{p}]$ (注意此时正则动量的符号改变了, 时间反演会无可避免地让速度反向)。这样良好的性质使得蛙跳法可用于反演、反推体系演化, 也使其保证了没有数值耗散 (因为耗散会破坏时间反演对称性, 相应地, 具有时间反演对称性的方法可免于耗散)。不过, 若使用可变步长, 则时间反演不变性往往会被破坏。

我们将辛欧拉法和蛙跳法运用于本节开头所述的问题中, 重新尝试积分星体轨道。在图 10 中可以看出, 即便积分精度并不高 (分别为一阶和二阶), 但由于保持了辛条件, 两种算法均使得系统的能量守恒在久期演化下得到了较好的保证, 即便经历数值振荡也会保证在真实值附近。为了多种目的, 人们还发明并使用了多种更高阶的辛算法用于轨道积分。但辛欧拉法及蛙跳法仍因其简单易行、势函数和加速度计算次数少, 而仍然在宇宙学大尺度结构模拟和部分星系结构模拟中占据主流地位。


习题

注意：本部分习题要求亲自编写解决常微分方程问题的代码，请勿调用现成的常微分方程求解库、函数或软件，否则不得分（但允许调用矩阵求解、矩阵及向量运算的库）。请自行选择带量纲或无量纲求解。附加题不做不扣分，做者加分；本次作业可超满分，补偿其他次作业分数。

习题 1.1. 天文学家发现了一个天体，命名为 WASP-69b，并于不久前对其各种参数进行了精细测量。

1. 请通过搜索简答：这是个什么类型的天体，它的质量和尺寸各是多少？这里的 WASP 是什么意思，69b 又是什么意思？存在 WASP-69a 吗？
2. 假定该天体是球对称的，全部由氢分子构成（不含氦或其他任何元素，不考虑氢分子分解），并进一步假定其符合理想气体状态方程，且整个天体具有均匀的比熵。求解该天体的内部结构（使用打靶法和松弛法皆可），绘制密度、压强与温度随半径的变化曲线（考虑在纵轴上使用对数坐标）。请注意：你得到的天体总质量与表面半径须与观测值符合。
3. 进一步的挑战：考虑更加符合实际的物态方程，该物态方程须保持等熵但并不符合绝热理想气体，而是由一个插值表格给出。继续假定该天体仅含氢，并使用 Miguel et al. (2016) 中给出的氢的物态方程表格（提示：请注意这些表格的输入输出参数各是什么；可使用偏导数关系： $[\partial \ln p / \partial \ln T]_s = -[\partial \ln s / \partial \ln p]_T / [\partial \ln s / \partial \ln T]_p$ ），通过插值给出物态方程，重复上一问的计算。
4. 附加题：假设该天体由氢氦构成，且氦的含量符合宇宙平均氦丰度。使用 Miguel et al. (2016) 中的氢与氦的物态方程表格，重复上一问的计算。请仔细思考并简要论证：欲使最终的物态方程在热力学上自洽，氢氦混合物的物态方程应当如何给出，混合熵是否有影响？

习题 1.2. 羟基 (OH) 自由基是一种常见的星际分子，其主要生成方式可等效为（简化改编自 Draine 2011, §33.2.2）：



本题假定总物质密度与温度皆均匀并不随时间变化（定容等温），且只考虑上述反应过程。请留意各反应速率参数的量纲。

1. 有一片均匀而稀疏的分子云，其 $t = 0$ 的初始时刻只含有 H_2 与 O ，且 $n(\text{H}_2) = 0.5 \text{ cm}^{-3}$ ， $n(\text{O}) = 1.6 \times 10^{-4} \text{ cm}^{-3}$ 。请依据上述反应机制，求 $t = 0$ 到 10^5 yr 时间段内 O 和 OH 分子数密度随时间的变化，并绘制所有相关化学物质浓度随时间的变化曲线。请首先以步长固定为 $\Delta t = 10^2 \text{ yr}$ 的欧拉方法求解，再以同等步长的标准四阶龙格——库塔法求解。
2. 将分子云初始密度改为原来的 10^2 倍，即 $n(\text{H}_2) = 50 \text{ cm}^{-3}$ ， $n(\text{O}) = 1.6 \times 10^{-2} \text{ cm}^{-3}$ ，其他条件不变，以同样的步长，重复上一问的计算。你遇到了什么严重问题？请用一阶半隐式方法，在相同的步长下重复上一问的计算，并同样绘制结果。

3. 附加题：请检测并展示第 2 问中的结果在多大程度上破坏了元素守恒。若要保持元素守恒始终成立，应该怎么办？请实现这个方法并重复第 2 问中的计算（提示：关键词 stoichiometric space）。

习题 1.3. 考虑一个最简化的恒星—行星体系，其中恒星固定不动，行星满足如下无量纲运动方程及初始条件：

$$\dot{\mathbf{q}} = \mathbf{p}, \quad \dot{\mathbf{p}} = -\frac{\mathbf{q}}{|\mathbf{q}|^3}; \quad \mathbf{q}|_{t=0} = [1, 0, 0]; \quad \mathbf{p}|_{t=0} = [0, 0.6, 0]; \quad (50)$$

1. 本习题计划使用蛙跳法，请证明：蛙跳法是一种辛算法。
2. 假定行星一直在 $x-y$ 平面内运动，请以二阶龙格—库塔方法及蛙跳法（保证参与对比的方法同阶），以 $\Delta\tau = 10^{-3}$ 的步长，分别将行星轨道积分至 $\tau = 10^2$ 。请绘制两种方法中水星总能量随演化时间的相对变化，及近星点角度随时间的变化（请自行拟定近似寻找近星点的数值手段）。
3. 将恒星的引力修改为帕钦斯基的伪牛顿引力，此时动力学方程改为：

$$\dot{\mathbf{q}} = \mathbf{p}, \quad \dot{\mathbf{p}} = -\frac{\mathbf{q}}{(|\mathbf{q}| - q_g)^2 |\mathbf{q}|}. \quad (51)$$

取无量纲史瓦西半径 $q_g = 10^{-2}$ ，使用相同的初始条件，请重复上一问的计算，并简述你的发现。

参考文献

- Draine, B. T. 2011, *Physics of the Interstellar and Intergalactic Medium* (Princeton University Press)
- Lam, S., & Goussis, D. 1989, *Symposium (International) on Combustion*, 22, 931
- Miguel, Y., Guillot, T., & Fayon, L. 2016, *A&A*, 596, A114
- Press, W. H., Teukolsky, S. A., Vetterling, W. T., & Flannery, B. P. 2002, *Numerical recipes in C++ : the art of scientific computing* (Cambridge University Press)
- 谈庆明. 2007, *量纲分析* (中国科学技术大学出版社)

2 椭圆型偏微分方程

偏微分方程 (partial differential equation, 简称 PDE) 是同时含有多个自变量的微分方程。它是描述科学与工程问题的最有效手段之一, 而其本身也是有重要意义的数学与应用数学问题。在日常的科研与工程实践中, 我们常将遇到的偏微分方程问题分类尝试解决。目前最通用也具有很大实践意义的分类方法是针对线性方程进行的 (非线性方程往往会通过局部线性化后纳入这一分类体系)。考虑二阶线性偏微分方程的一般形式:

$$a \frac{\partial^2 u}{\partial y^2} + b \frac{\partial^2 u}{\partial y \partial x} + c \frac{\partial^2 u}{\partial x^2} + d \frac{\partial u}{\partial y} + e \frac{\partial u}{\partial x} + f u + g = 0, \quad (1)$$

其中 a 到 g 各系数皆可为 (x, y) 的函数 (若为 u 或 u 的导数的函数则为非线性方程, 若为 u 的线性函数则为准线性方程¹)。上式可以通过 $(x, y) \rightarrow (\xi, \eta)$ 的变量代换, 成为标准形式 (canonical form):

$$\frac{\partial^2 u}{\partial \xi^2} + \zeta \frac{\partial^2 u}{\partial \eta^2} = \Phi \left(\frac{\partial u}{\partial \xi}, \frac{\partial u}{\partial \eta}, u, \xi, \eta \right), \text{ 其中: } \zeta \in \{-1, 0, 1\}. \quad (2)$$

通过形式上类比二次曲线方程, 人们发展出以下称谓: 若 $\zeta = 1$, 上式称为**椭圆型**偏微分方程 (elliptical PDE); 若 $\zeta = 0$, 则称**抛物型**偏微分方程 (parabolic PDE); 若 $\zeta = -1$, 则称**双曲型**偏微分方程 (hyperbolic PDE)。三类方程分别对应着方程 (1) 中的判别式 ($b^2 - 4ac$) 小于零、等于零、大于零的情况 (证明不难, 留作练习)。其中, 双曲型方程可以化为:

$$\left(\frac{\partial}{\partial \xi} + \frac{\partial}{\partial \eta} \right) \left(\frac{\partial}{\partial \xi} - \frac{\partial}{\partial \eta} \right) u = \Phi \quad (3)$$

的形式, 这一形式很显然具有特征线、推迟解、波动方程形式等导致守恒律的突出特性, 其现代化求解往往有严格保持守恒律等特定需求, 我们将在下一章讨论。但即便是双曲方程, 若须考量其稳态结果 ($\partial u / \partial t = 0$), 其空间部分将构成一个椭圆方程。而在本章的晚些时候我们也将发现, 抛物型方程的数值求解往往可以直接进行, 或纳入椭圆型方程的框架中。因此, 本章主体将针对椭圆型偏微分方程的数值求解进行讨论。为书写方便起见, 我们引入简化记号:

$$u_x \equiv \frac{\partial u}{\partial x}, \quad u_{xx} \equiv \frac{\partial^2 u}{\partial x^2}, \quad \dots \quad (4)$$

本节中, 为简便起见, 我们将反复以如下一维的泊松方程为例,

$$\frac{d^2 u}{dx^2} = -v(x), \quad u|_{x=-1} = u|_{x=1} = 0, \quad v(x) = \Theta(0.25 - |x|), \quad (5)$$

以演示和实践不同的椭圆方程求解方式。

2.1 最接近解析的求解方式: 傅里叶变换

在数学物理方程等数理基础课程中, 我们学习过线性偏微分方程的解析求解, 特别是通过分离变量法求解 (请回忆分离变量法适用的前提——线性、无交叉导数项), 但对其的傅里叶变换求解则往往一笔带过。这既有课程设置目的的原因 (数理方法往往以理论教学为主), 也有时代和历史的原因 (目前教材编写者在科研上活跃时计算技术与方法不普及)。但无论如何, 这两种方法间逻辑联系的缺失所反映的数理方法实践教学上的缺失, 似乎是一个世界性的遗憾。本课程拟对此略作弥补。

¹有许多不同的关于准线性或半线性的定义, 本课程不深究。

傅里叶变换求解椭圆型偏微分方程，在形式上是相当直接的。记函数 u 与其傅里叶变换为 $\tilde{u}_{\mathbf{k}}$ ，本课程采取如下定义的连续傅里叶变换与逆变换的方式：

$$\tilde{u}_{\mathbf{k}} = \mathcal{F}[u] \equiv \frac{1}{(2\pi)^{d/2}} \int d^d \mathbf{x} u(\mathbf{x}) e^{-i\mathbf{k} \cdot \mathbf{x}} ; \quad u(\mathbf{x}) = \mathcal{F}^{-1}[\tilde{u}_{\mathbf{k}}] \equiv \frac{1}{(2\pi)^{d/2}} \int d^d \mathbf{k} \tilde{u}_{\mathbf{k}} e^{i\mathbf{k} \cdot \mathbf{x}} . \quad (6)$$

式中 d 为问题的维数，而我们采取了令 $\mathcal{F}$ 与 $\mathcal{F}^{-1}$ 形式上尽可能对称的定义方式。本章中，我们始终假定 u 具有足够好的微分性质，故对方程进行的傅里叶变换中的积分操作可与求导操作交换位置，进而有（若不熟悉向量微分算符 ∇ 对函数作用时的表现形式，请首先自行替换为“传统”的偏导数形式进行理解，并尽快熟悉新的形式）：

$$\mathcal{F}[\nabla u] = -i\mathbf{k}\tilde{u}_{\mathbf{k}} ; \quad \mathcal{F}[\nabla^2 u] = -\mathbf{k}^2\tilde{u}_{\mathbf{k}} , \quad (7)$$

式中， u 的梯度经傅里叶变换后仍为向量，而 u 的拉普拉斯算符经变换后为标量。在此基础上，我们首先考虑一个无穷远边界条件下的泊松方程，并对其进行傅里叶变换及逆变换后可得：

$$\nabla^2 u = g \Rightarrow -\mathbf{k}^2\tilde{u}_{\mathbf{k}} = \mathcal{F}[g] \Rightarrow u = \mathcal{F}^{-1}\{-\mathbf{k}^{-2}\mathcal{F}[g]\} . \quad (8)$$

这正是天体物理中最常见的求解椭圆方程的情形：由空间中任意质量分布得到引力势分布。而且，若令 $g \equiv \delta^3(\mathbf{x} - \mathbf{x}_0)$ 为一单点质量分布（ δ^3 为三维的狄拉克 Delta 函数），则所得的 $u = 1/|\mathbf{x} - \mathbf{x}_0|^2$ 即为泊松方程的格林函数；结合线性方程的格林定理、傅里叶变换的卷积定理以及方程解在无穷远处为零的边界条件，将格林函数与质量分布进行卷积，原则上即可得到引力势的分布——当然，这样的求解因其复杂度为 $O(N^2)$ 而只有理论意义（事实上，数值卷积的计算往往反而须借助傅里叶变换进行）。

需要指出的是，计算机在数值上并不能真正处理连续的变量、无穷大的坐标，而只能进行离散的表述、覆盖有限的范围。在傅里叶空间中，离散的点意味着原函数只能定义在有限长的区间内，并在此区间外具有周期性——以原区间长为周期，重复原区间（这一证明并不复杂，留给有兴趣的读者）。当我们利用数值傅里叶变换解决问题时，所求的结果事实上是蕴含了周期性、离散性的假设的。

2.1.1 快速傅里叶变换原理

快速傅里叶变换（fast Fourier transform，简称 FFT）以其强大和关键的实用性、启发性，以及其对计算机技术和其他相关技术应用的革命性改变，位列 20 世纪十大算法之一。它事实上是对基本的离散傅里叶变换（descrete Fourier transfor，简称 DFT，勿与密度泛函理论混淆）算法的重大改进，通过分治、复用等方法，将算法复杂度从 $O(N^2)$ 下降到 $O(N \log N)$ ，使得离散傅里叶变换对具有一定规模的数据首次有了实际的可行性。借着讲解椭圆方程求解方法之机，我们可对这一具有历史意义的算法有一管窥之见。

离散傅里叶变换

离散傅里叶变换的表达式较为简单。考虑如此情形：函数定义在一维均匀离散网格，且在其两端采用周期性边界条件。为了方便论述，我们进一步假设网格的格点数为 2 的幂，即 $N \equiv 2^{\mathcal{N}}$ ， $\mathcal{N} \in \mathbb{N}$ 。此时， $x_i = iL/N$ ，周期性边界条件会令 $x_0 = x_N$ （而非 x_{N-1} ）；记 $u(x_i)$ 为 u_i ，则 u 的离散傅里叶变换 $\{w_l\}$ 及令其“返回” $\{u_i\}$ 的逆变换可表达为（本节用 i, j, k 表达位形空间指标，用 l, m, n 表达傅里叶空间/波数空间指标）：

$$w_l = \sum_{i=0}^{N-1} u_i e^{-(2\pi i/N)il} ; \quad u_i = \frac{1}{N} \sum_{l=0}^{N-1} w_l e^{(2\pi i/N)il} . \quad (9)$$

上述运算与公式 (6) 给出的连续傅里叶变化相比, 容易论证其类同性及 $N \rightarrow \infty$ 时的一致性 (当然此时须对 u_i 的中间点做 $N/2$ 的位移)。同时, 如此所得的 $\{u_j\}$ 与原来相等 (即离散傅里叶变换的正交完备性, 证明留作练习), 且具有 $u_{i+N} = u_i$ 的周期性。另外, $\{w_l\}$ 也具有 $w_{l+N} = w_l$ 的周期性, 这意味着数学上有意义的 $\{w_l\}$ 一共有 N 个。每个 w_l 的得出须进行的运算次数正比于 N ; 为了求出所有的 $\{w_l\}$, 我们一共须进行的计算次数正比于 N^2 , 即算法的时间复杂度为 $O(N^2)$ 。这样的时间复杂度是无法接受的: 按 32 位浮点数 (每个 4 B) 计, 若欲以此处理 4 kB 数据, 则以复数乘法为准, 计算量将有 $1024^2 \sim 1 \text{ M}$ 次, 尚可接受; 若欲处理 4 MB 数据, 则总计算量将高达 $1024^4 \sim 1 \text{ T}$ 次——这即便在今日的计算机技术之下也是须用高性能硬件处理数十分钟的, 遑论更早期硬件性能低下时, 或在移动设备上处理时, 或是处理更大规模数据时。所以一般认为, “标准”的离散傅里叶变换是不具备实用性的。

快速傅里叶变换

如果仔细观察公式 (9), 会发现其中存在着相当多的冗余与浪费。最直观的一点是, 考虑到 $e^{-(2\pi i/N)il}$ 关于指标乘积 il 将会出现许多相同的结果, 同时考虑到其对 il 所具有的 N 的周期性, 事实上有许多貌似独立的运算 (特别是超出 “第一布里渊区” 的部分) 只是进行了许多无益的重复。另一个考虑问题的角度是如下恒等式 (以下令 $W \equiv e^{-(2\pi i/N)}$; 请勿混淆斜体的指标 i 与正体的虚数单位 i):

$$w_l = \sum_{i=0}^{N/2-1} u_{2i} W^{2il} + \sum_{i=0}^{N/2-1} u_{2i+1} W^{(2i+1)l} \quad (10)$$

$$\equiv w_l^e + W^l w_l^o.$$

图 1: $N = 8$ 的快速傅里叶变换过程中的 “数据流向”。此图又称 “蝴蝶图” (butterfly diagram)。

$$w_{l+N/2} = \sum_{i=0}^{N/2-1} u_{2i} W^{2i(l+N/2)} + \sum_{i=0}^{N/2-1} u_{2i+1} W^{(2i+1)(l+N/2)} \equiv w_l^e + W^{l+N/2} w_l^o \equiv w_l^e - W^l w_l^o \quad (11)$$

也即, 对任意 l 而言, w_l 与 $w_{l+N/2}$ 可由同样的两个 “源头” (w_l^e 与 $W^l w_l^o$) 相加、相减得到。进一步地, 我们可以对 w_l^e 和 w_l^o 进行分解, 得到:


$$w_l^e = w_l^{ee} + W^{2l} w_l^{eo}, \quad w_l^o = w_l^{oe} + W^{2l} w_l^{oo}. \quad (12)$$

此时的 W^{2l} 对 l 的周期为 $N/2$, 故亦有:

$$w_{l+N/4}^e = w_l^{ee} - W^{2l} w_l^{eo}, \quad w_{l+N/4}^o = w_l^{oe} - W^{2l} w_l^{oo}. \quad (13)$$

容易论证, 如此递归地分解, 总能将 w_l 分解 “到底”, 成为:

$$w_l^{(\cdots)} = w_l^{(\cdots)e} + W^{(N/2)l} w_l^{(\cdots)o}, \quad w_{l+1}^{(\cdots)} = w_l^{(\cdots)e} - W^{(N/2)l} w_l^{(\cdots)o}. \quad (14)$$



在这个“极端”情形下， $W^{(N/2)l} = (-1)^l$ ，而 $w_l^{(\cdots)e}$ 和 $w_l^{(\cdots)o}$ 事实上只是 $\{u_i\}$ 中某两个元素本身，并未乘以 W 的任何次幂。由递归过程中的奇偶拆分我们发现一个规律：首次拆分时， w_l^e 所包含的所有 u_i 元素，其指标 i 必为偶数，即二进制表示的末位必为 0；而 w_l^o 所包含的 u_i 的指标 i 二进制末位必为 1。在下一轮拆分中，同样的规律仍然成立： w_l^{ee} 所需 u_i 之 i 必可被 4 整除，即二进制下末两位为 00；而 w_l^{eo} 所需 u_i 之 i 的二进制末两位为 10，等等。最终， $w_l^{(\cdots)}$ 所需的 u_i 的 i 指标，正是其奇偶指标对应于一个二进制数后（其中 e 对应于 0，而 o 对应于 1）在 $\mathcal{L} = \log_2 N$ 个二进制位之下的“反向”。若将 i 在 $\mathcal{L}$ 位下的“二进制反向”记为 $\tilde{i}$ ，则我们应先将输入的数组 $\{u_i\}$ 重新排布为 $\{u_{\tilde{i}}\}$ ，再依照上述递归推导的逆过程，逐层进行操作。以 $N = 8$ 为例，在此过程中的“数据流向”如图 1 所示。

对上述运算稍事总结即可发现，这些运算可被分为 $\mathcal{L} = \log_2 N$ 个层次。每个层次内每个元素运算时将只须从上一层次中取两个元素进行“组合”即可得出，故每层内运算数量正比于 N 。总之，快速傅里叶变换的时间复杂度为 $O(N \log_2 N) \sim O(N \log N)$ ，而空间复杂度为 $O(N)$ 。相比于“标准”的离散傅里叶变换，FFT 可加速 $\sim (N/\log_2 N)$ 倍，这使得傅里叶变换真正成为了一种实用的算法。

2.1.2 傅里叶变换方法的优缺点

傅里叶变换方法既然跻身 20 世纪十大算法之列，必有其过人之处。此处不论其他方面的用途，单论椭圆方程求解，即可列出大量优势。它的数学与物理意义明确，对问题的“病态性”（可理解为求解结果对输入的敏感性，该敏感性越强问题越病态）不甚敏感，内存消耗与计算代价皆可控且通常不高。在编程技术上，由于其在不同领域广泛而深入的应用，FFT 的算法标准化程度很高；自行开发并不困难，同时更是存在着各种高度成熟、高度优化、兼容性与可移植性极好、可在各类并行系统乃至 GPU 等类向量系统上高效运行的 FFT 软件库；其中最负盛名的实为 FFTW。由于标准化程度高，使用者往往可以略过在其他方法中极其复杂的编程与调试环节，通常可以较少的开发代价快速、可靠地获得结果。

然而，这并不意味着傅里叶变换方法是完美无缺的。最直观的问题是，本节的论证全部针对 $2^{\mathcal{L}}$ 的网格点数进行；若无法满足此条件，则往往须通过按需补零或插值的方法使数据满足这一要求，这无疑增加了额外的计算代价，还可能导致更多的偏差。二维乃至三维的傅里叶变换看上去非常直接，但若用于稍具规模的数据，便会涉及大规模数据的转置读写，例如：若对一个二维体系沿 y 方向进行傅里叶变换，则每次从数据集中读取一列时，该列相邻两个元素取自 $\tilde{u}_{i,j}$ 与 $\tilde{u}_{i,j+1}$ ，但这两个元素在内存中并不相邻，而是隔着相当远的实际距离（等于 x 方向的格点数），这与处理器缓存预取数据的方式完全不匹配；同时，每次得到沿 y 方向的一列数据，这样的不匹配发生的次数便与该列长度相等，导致缓存未命中几乎成为常态，内存读写速度大受影响（会减慢一个甚至多个数量级）。一旦用于大规模分布式内存模型的设备，这样的麻烦还会因跨节点大规模读写数据的需求而随着问题规模被迅速放大。

相比晚些时候提及的基于迭代的方法，傅里叶变换方法的另一个劣势在于不能有效利用“猜测值”。在天体物理模拟中，不论用于求解流体自身引力场还是扩散极限下的辐射场问题，待求解的场往往与当前流体构型直接相关。由于流体力学部分所谓 CFL 条件的限制（将在下一章叙述，可简单理解为：流体力学会限制每一步时间演化的时长，以避免物质、能量、动量在该步的传输距离超过半个格点尺度，进而保证因果律不被破坏、保证算法稳定），相邻两步间的流体构型必定非常相近，致使上一步的场求解结果往往是本步的一个极好“猜测”。基于迭代的方法可因此充分得益、大幅减小收敛代价，使时间复杂度降至 $O(N)$ ；而傅里叶变换方法则完全无法利用这一特点，只能在每一步全部从头算起。

综上，傅里叶变换方法求解椭圆方程的优缺点都相当显著，而这些特点也为我们选择算法提供了限制，或曰依据。一般来说，对中小规模、低维度（特别是一维）、跨进程或跨节点并行度不高、对开发代

价有需求（如须尽快成型、给出结果）的椭圆方程求解任务而言，傅里叶变换是一个较为理想的选择。若问题规模大、调用次数多、计算速率需求高，则应认真考虑使用下文叙述的基于迭代的其他方法。

2.2 简明易行的迭代：梯度下降法简介

上一节所述的傅里叶变换法可被视为一种“直接方法”。若将微分算符改为矩阵形式，原则上此矩阵亦可直接求解，然而除少数情形外，直接求解矩阵一般被认为是不现实的。考虑常微分方程一章中所叙述过的操作——将微分方程的微分算符“转化”为矩阵、将待求的场转化为待解的向量、将源项转化为非齐次项，原则上直接求解（即用高斯消去法或其变种，如 LU 分解等）矩阵的代价为 $O(N^3)$ （注意此处 N 为总的格点数）。当维数提高时，此值增加速度甚至将大幅度快于格点本身的指数增速，以至于事实上无法承受。得益于矩阵的“稀疏性”（即大部分元素为零），待解问题的有效数据数量事实上远小于 N^2 而是正比于 N ，原则上应当有更合适的方法。在问题为一维且边界条件满足特定条件时，该矩阵将具有所谓三对角形态，这使所谓追逐求解成为可能；但当维度较高，或边界条件为较一般情况时，追逐法也将失效，我们必须寻求更一般的方法。

为了得到一个简易的迭代求解方法。我们考虑形式上已经转化为非齐次线性方程组求解的椭圆方程问题，记为 $Au = b$ ，并假定 A 是满秩（非奇异）的（这一条件大致等价于椭圆方程本身的适定性）。所谓迭代方法，实为从某个初始猜测开始、逐步改进方程解的猜测的过程。令其在第 m 步迭代时的猜测值为 $\tilde{u}^{(m)}$ ，仍记 $e^{(m)} \equiv \tilde{u}^{(m)} - u$ 为此时的残差，则关于非齐次项的残差平方（记为 $g^{(m)} \equiv g[\tilde{u}^{(m)}]$ ，为一标量）满足：

$$g^{(m)} \equiv |Ae^{(m)}|^2 \equiv |A(\tilde{u} - u)|^2 = |Au^{(m)} - b|^2. \quad (15)$$

此处向量的模取一般定义（各项平方和的正平方根）。若猜测值与目标解无差异，一定有 $g^{(m)} = 0$ ——问题被成功地转化为一个“令某标量为零”的单参数多变量优化问题。一个显而易见的做法是对 $g^{(m)} = 0$ 进行牛顿法迭代求解，即：

$$\tilde{u}^{(m+1)} = \tilde{u}^{(m)} - \frac{g^{(m)}}{\partial g^{(m)} / \partial \tilde{u}^{(m)}} = \tilde{u}^{(m)} - \frac{g^{(m)}}{2A^2 \tilde{u}^{(m)}}. \quad (16)$$

这一方法看上去简单、直接，只须沿各个方向求数值导数即可，但实践中几乎无人采用。为什么呢？

2.2.1 条件数：为何要“多此一举”？

回忆常微分方程一章中关于条件数的描述：非奇异矩阵 A 的条件数为其最大与最小本征值的比值，且条件数越大、矩阵越“病态”。所谓病态程度，一般是指 Au 的值对 u 的敏感程度——越敏感，则越难以从 $Au = b$ 获得 u 的准确值，矩阵的病态程度也就越高。我们记 b 上的偏差向量为 e ，则矩阵 A 对偏差的传递情况可以用如下表达：

$$\text{源偏差: } \frac{\|e\|}{\|b\|}, \text{ 解偏差: } \frac{\|A^{-1}e\|}{\|A^{-1}b\|}, \text{ 传递: } \left[\frac{\|e\|}{\|b\|} \right]^{-1} \frac{\|A^{-1}e\|}{\|A^{-1}b\|} = \frac{\|A^{-1}e\|}{\|e\|} \left[\frac{\|A^{-1}b\|}{\|b\|} \right]^{-1}. \quad (17)$$

其中 $\|A\|$ 为矩阵 A 的范数，可以理解为将矩阵本身当做线性空间后，已成为“向量”的 A 的模——由于任意满足正定性（对任意 $A \neq 0$ 有 $\|A\| > 0$ ）、线性性（ $\|kA\| = |k|\|A\|$ ）、三角不等式（ $\|A + B\| \leq \|A\| + \|B\|$ ）、几何不等式（ $\|AB\| \leq \|A\|\|B\|$ ）的由矩阵到实数映射都可以称为范数，事实上范数的具体定义非常多样，且往往会依据数学上的具体需求进行选定。当保持 e 为微扰，并令 b 取遍所有可

能非退化（即 $b \neq 0$ ）情形，上式的最大可能值（上界）满足：

$$\begin{aligned} \max \left[\frac{\|A^{-1}e\|}{\|e\|} \left(\frac{\|A^{-1}b\|}{\|b\|} \right)^{-1} \right] &= \max \left[\frac{\|A^{-1}e\|}{\|e\|} \right] \max \left[\frac{\|b\|}{\|A^{-1}b\|} \right] \\ &= \max \left[\frac{\|A^{-1}e\|}{\|e\|} \right] \max \left[\frac{\|Au\|}{\|u\|} \right] = \|A^{-1}\| \|A\|. \end{aligned} \quad (18)$$

上式的具体值可能会随着范数定义的不同而改变，但人们常常用本征值给出其估计。由范数的线性性，若 λ 为 A 的任一本征值，则对由该本征值对应本征向量构成的矩阵 B （构造 B 的最简单方法是令 B 的每一列都是该本征向量），由范数的线性性及几何不等式，有：

$$|\lambda| \|B\| = \|\lambda B\| = \|AB\| \leq \|A\| \|B\|, \quad (19)$$

所以对任意本征值， $\|A\| \geq |\lambda|$ ；进而，给出最“贴近” A 的范数的估计方式，可取为其最大本征值。由于 A^{-1} 的各本征值为 A 各本征值的倒数，故 $\|A^{-1}\|$ 模最大的本征值是 A 模最小本征值的倒数。若令 A 的本征值分解为 $A = \Lambda^{-1} \text{diag}(\lambda_0, \dots, \lambda_{N-1}) \Lambda$ （其中 λ 绝对值依次减小），按最常见的条件数定义：

$$\text{cond}(A) \equiv |\lambda_0/\lambda_{N-1}|, \quad (20)$$

则该定义往往能有效地对相对误差的传递（公式 18）进行估计。事实上，若取 $\|\cdot\|$ 为所谓 l_2 矩阵范数（可等同于以 $|\mathbf{a}|^2 = \sum_i |a_i|^2$ 定义的“常规”向量模），且若 A 为正规矩阵（或称为厄米矩阵，即 $AA^* = A^*A$ ， A^* 为 A 的复共轭转置；在 A 表达离散化的微分算符时，此条件等效于对不同变量求导的操作可交换），可以证明 $\text{cond}(A) = \|A^{-1}\| \|A\|$ （具体证明留作练习）。从物理图像上看， $\text{cond}(A)$ 事实上表征了以 A 定义的方程组（也对应于其所表达的离散化的微分方程组）中变化最快与最慢的模式的变化速度之比——这也就是方程组本身的“刚性”（常微分方程部分的对应表述与此处几乎一致）。

条件数的引入使我们有了判别数值方法优劣的有效判据。前述的“简单”方法中，我们求解的系统所涉及的矩阵事实上是 A^2 （见公式 16），而其本征值分解为 $A^2 = \Lambda^{-1} \text{diag}(\lambda_0^2, \dots, \lambda_{N-1}^2) \Lambda$ ，故有 $\text{cond}(A^2) = |\lambda_0/\lambda_{N-1}|^2 = \text{cond}^2(A)$ 。矩阵的“病态”程度因而变成了原来的平方。实践上有一个直观的经验规则：若矩阵条件数为 10^k 量级，则其求解过程中因为数值敏感性而“损失”的有效数字也为 k 位（即当变化最慢的模式取值调整的数量级为 10^{-k} 时，变化最快的模式将发生数量级为 1 的变化，这将导致快慢模式的相互作用完全无法得到准确追踪），故需至少 $k+1$ 位有效数字方可保证线性方程组的求解过程不至于发散。若问题的条件数变为原来的平方，则无疑将极大地增加求解的难度和计算开销（当数值精度不够时，求解甚至无法收敛），进而与“精确而快速地求解方程”这一根本目标南辕北辙。

2.2.2 共轭梯度

如何改变这一问题？一个具有启发性的想法是，若 A 为对称矩阵，则由于其给出二次型的正定性，我们可以通过寻求 $f(u) \equiv u^T A u / 2 - u^T b$ 的极值——意味着 $\partial f / \partial u = Au - b = 0$ ——来寻求原方程的解。最直观地看，我们可以使用简单的梯度下降法来求解，即令 $x_{l+1} = x_l - \alpha \partial f(x_l) / \partial x_l = x_l - \alpha(Ax_l - b)$ ，并适当对 α 取值来进行。然而，这种做法的收敛速度和稳定性一般不尽人意。本节中，我们推导一种更好的方法。

关于 A 正交的基向量组构建

为了方便讨论，我们以待“求解”的矩阵 A （仍然假设其满秩）为基础，定义一种新的、暂时只在本节内适用的内积，称为“ A -内积”： $\langle u, v \rangle_A \equiv u^T A v$ （请格外注意分辨此内积与不借助 A 的“常规”




图 2: 共轭梯度方法对方程 (5) 求解的过程及结果。

内积: $\langle u, v \rangle \equiv u^T v$ 。借助这样的内积, 我们可以定义一组正交完备基, 即:

$$\{p_i\}, i = 0, 1, 2, \dots, N-1; \quad \langle p_i, p_j \rangle_A = \delta_{ij}. \quad (21)$$

若真正具备这组基, 我们事实上可以直接求解原本方程组。令 $x = \sum_i \alpha_i p_i$, 可将其代入原方程:

$$Ax = A \sum_i \alpha_i p_i = b \Rightarrow p_j Ax = p_j A \sum_i \alpha_i p_i \Rightarrow \alpha_j = \langle p_j, b \rangle. \quad (22)$$

原则上, 求得正交归一完备基组 $\{p_i\}$ 的方法有很多, 如常见于高等代数或量子力学教材、用于论证正交归一基存在性的格拉姆—施密特正交化过程 (Gram-Schmidt process)。其基本思路是, 首先以 l 个线性独立且相互之间两两依 A -内积正交的向量为基础:

$$\langle p_i, p_j \rangle_A = \delta_{ij} \langle p_i, p_i \rangle_A, \quad i, j = 0, 1, \dots, l-1, \quad (23)$$

若此时引入一向量 v_l , 其与现有各 p_i 皆线性独立, 则可以下式中的方法向正交基组 $\{p_i\}$ 中添加新的成分 (容易证明这样得来的 p_l 与各个已有基向量皆 A -正交):

$$p_l = v_l - \sum_{i=0}^{l-1} \frac{\langle v_l, p_i \rangle_A}{\langle p_i, p_i \rangle_A} p_i, \quad (24)$$

依照数学归纳法, 即可由任意未正交归一的 $\{v_i\}$ 基向量组生成依 A -内积正交的向量组 $\{p_i\}$ 。这一方法的计算复杂度较高, 为 $O(N^3)$ 时间复杂度、 $O(N^2)$ 空间复杂度 (N 为格点总数)。较高空间复杂度使求解难以实际开展, 且舍入误差的累积会使得较后引入的向量的实际正交性较差。同时, 即便获得了正交基, 最终的求解结果也并不易得到: 获取全部展开系数 $\{\alpha_i\}$ 并将其还原为实际求解结果的总代价约为 $O(N^2)$ 量级。

残差向量带来截断的基组——共轭梯度基本思路

尽管不能直接应用, 上述推导仍为我们得出现实可用的方法提供了思路。仍然考虑函数 $f(u) = u^T A u / 2 - u^T b$ 的极值问题, 并假定此时矩阵 A 为对称的。因该二次型在整个高维空间中有且仅有一个极值存在, 若不考虑数值误差, 只须在**每个维度**找到这个极值的“位置”即可找到该极值, 并等效地

求解了原方程。在这一思路下，我们尝试使用递推方法解决问题。记第 l 步中的残差为 $r_l \equiv Ax_l - b$ ，并记已找到的基组为 $\{p_i\}$ ($0 \leq i \leq l-1$)。在第 l 步中，对 $f(u)$ 求导后可知，梯度下降的方向正是 r_l 。但结合上文所述思路，实际采取的方向应与先前所有方向皆 A -正交，故若将迭代形式上写作 $x_l = x_{l-1} + \alpha_{l-1}p_{l-1}$ ，为使其在当前维度上使函数 f 取约束极值，可令 $\partial f(x_{l-1} + \alpha_{l-1}p_{l-1})/\partial \alpha_{l-1} = 0$ ：

$$\frac{\partial f(x_{l-1} + \alpha_{l-1}p_{l-1})}{\partial \alpha_{l-1}} = [A(x_{l-1} + \alpha_{l-1}p_{l-1}) - b]^T p_{l-1} = r_l^T p_{l-1} = 0 \Rightarrow \alpha_{l-1} = -\frac{\langle r_{l-1}, p_{l-1} \rangle}{\langle p_{l-1}, p_{l-1} \rangle_A}, \quad (25)$$

注意，这一给出 α_l 的方式蕴含着 $\langle r_l, p_{l-1} \rangle = 0$ 。在此构造方式下，对任意 $j \leq l-1$ ，因 $\langle p_{l-1}, p_j \rangle_A = 0$ ：

$$\begin{aligned} \langle r_l, p_j \rangle &= \langle Ax_l - b, p_j \rangle = \langle A(x_{l-1} + \alpha_{l-1}p_{l-1}) - b, p_j \rangle = \alpha_{l-1} \langle p_{l-1}, p_j \rangle_A + \langle r_{l-1}, p_j \rangle \\ &= \langle r_{l-1}, p_j \rangle = \cdots = \langle r_{j+1}, p_j \rangle = 0. \end{aligned} \quad (26)$$

同时，由公式 (24)，取新引入的线性独立向量为 r_l ，令 p_l 与已有的各基满足 A -正交条件意味着：

$$p_l = r_l - \sum_{i=0}^{l-1} \frac{\langle p_i, r_l \rangle_A}{\langle p_i, p_i \rangle_A} p_i. \quad (27)$$

上式首先表明，对 $j \leq l-1$ ，结合 $\langle r_l, p_{j < l} \rangle = 0$ 有：

$$\langle r_l, r_j \rangle = \langle r_l, p_j \rangle + \left\langle r_l, \sum_{i=0}^{j-1} \frac{\langle p_i, r_j \rangle_A}{\langle p_i, p_i \rangle_A} p_i \right\rangle = 0. \quad (28)$$

其次，注意到 $r_{l+1} - r_l = A(x_l + \alpha_l p_l) - Ax_l = \alpha_l A p_l$ ，结合以上两式，有：

$$\begin{aligned} p_l &= r_l - \sum_{i=0}^{l-1} \frac{\langle p_i, r_l \rangle_A}{\langle p_i, p_i \rangle_A} p_i = r_l - \sum_{i=0}^{l-1} \frac{\alpha_i^{-1} \langle (r_{i+1} - r_i), r_l \rangle}{\langle p_i, p_i \rangle_A} p_i = r_l - \alpha_{l-1}^{-1} \frac{\langle r_l, r_l \rangle_A}{\langle p_{l-1}, p_{l-1} \rangle_A} p_{l-1} \\ &= r_l + \frac{\langle r_l, r_l \rangle_A}{\langle r_{l-1}, p_{l-1} \rangle_A} p_{l-1} = r_l + \frac{\langle r_l, r_l \rangle_A}{\langle r_{l-1}, r_{l-1} \rangle_A} p_{l-1}. \end{aligned} \quad (29)$$

上式中，最后一个等号处使用了 $\langle r_l, p_j \rangle$ ($\forall j < l$)。这样的递推方式，彻底避免了记录已有基向量带来的 $O(N^2)$ 空间复杂性，使算法的实际应用成为可能。数值近似解 x_l 在每一步中的前进方向并非 r_l (f 在该处梯度)，而是经由递推关系构建的 p_l (称为共轭梯度，因此处 A -正交也被称为“共轭”)——这一操作充分利用了矩阵 A 的性质，且原则上是一个在 N 步内准确解决问题的方法 (见公式 22)。总之，共轭梯度法可以伪代码的方式描述，如算法 1 所示。其中 ϵ 为误差控制量，而残差 r_l 采用计算代价更低的递推方式表达——容易证明这样给出的 r_l 在数学上与由定义给出的 $r_l \leftarrow Ax_l - b$ 等效，但随着迭代的进行，这一表达式难免遭遇累积误差的困扰，故须间歇性按定义计算 r_l 以消除累积误差。作为一

Algorithm 1 共轭梯度 (CG) 算法。

```

 $r_0 \leftarrow Ax_0 - b$ ;  $p_0 \leftarrow r_0$ 
while  $r_l^T r_l > \epsilon$  do
   $\alpha \leftarrow -\frac{r_l^T r_l}{p_l^T A p_l}$ 
   $x_{l+1} \leftarrow x_l + \alpha p_l$ ;  $r_{l+1} \leftarrow r_l + \alpha A p_l$ 
   $p_{l+1} \leftarrow r_{l+1} + \frac{r_{l+1}^T r_{l+1}}{r_l^T r_l} p_l$ 
end while

```

个简单的一维例子，我们使用共轭梯度方法求解泊松方程 (5)，求解的结果及收敛过程展示于图 (2) 中。

数学上有一个描述上述共轭梯度方法的特别角度。记 $\mathcal{K}^{(l+1)} \equiv \text{span}\{b, Ab, \dots, A^l b\}$ 为 $(l+1)$ -维的克雷洛夫子空间 (Krylov subspace)。当我们令 $x_0 = 0$ ，则上述方法的 x_1 必沿 b 展开。若 $x_l \in \mathcal{K}^{(l)}$ ，则由 $x_{l+1} = x_l + \alpha_l p_l$ 结合公式 (29) 可知， $x_{l+1} \in \mathcal{K}^{(l+1)}$ ，进而由数学归纳法得知 $x_l \in \mathcal{K}^{(l)}$ 对各 l 皆成立。在不考虑数值误差时，精确解 $x_N \in \mathcal{K}^{(N)}$ ；又因为 x_l 建立在 $\{p_{i < l}\}$ 基础上，记 $\{p_{i < l}\}$ 所构成的投影算符为 $\mathcal{P}_l$ ，则 $x_l = \mathcal{P}_l x_N$ (另一等效表述为， x_N 在后继于 x_l 的补充部分 $\{p_{i \geq l}\}$ 必与 x_l 构成 A -正交)，故 x_l 可视为 x_N 在 $\mathcal{K}^{(l)}$ 上的投影。因此，共轭梯度法被归为一种“克雷洛夫子空间方法”。

2.2.3 双共轭梯度与几何共轭梯度：因地制宜

Algorithm 2 双共轭梯度 (BiCG) 算法。

```

 $r_0, r'_0 \leftarrow Ax_0 - b; p_0, p'_0 \leftarrow r_0$ 
while  $r_l^T r_l > \epsilon$  do
   $\alpha \leftarrow -\frac{r_l^T r_l}{p_l^T A p_l}$ 
   $x_{l+1} \leftarrow x_l + \alpha p_l; x'_{l+1} \leftarrow x'_l + \alpha p'_l$ 
   $r_{l+1} \leftarrow r_l + \alpha A p_l; r'_{l+1} \leftarrow r'_l + \alpha A^T p'_l$ 
   $\beta \leftarrow \frac{r_{l+1}^T r_{l+1}}{r_l^T r_l}$ 
   $p_{l+1} \leftarrow r_{l+1} + \beta p_l; p'_{l+1} \leftarrow r'_{l+1} + \beta p'_l$ 
end while

```

上一节的论述有一个前提： A 是对称矩阵。一般情况下，微分方程所对应的矩阵 A 并不一定是对称的。此时最简单的想法是，将 $Au = b$ 化为 $A^T A u = A^T b$ 即可求解 (因 $A^T A$ 必为对称矩阵)，然而这样将使得被求解的矩阵条件数变为原先的平方，同样会给求解造成额外的 (有时是巨大的) 麻烦。人们因此引入了所谓的双共轭梯度法 (Bi-Conjugate Gradient method, 简称 BiCG)。这一方法的核心是针对矩阵 A 的左侧 (行向量) 空间定义另一组辅助向量，并在左右两侧同时进发 (参见算法 2)——此时该算法与标准共轭梯度法非常相似。然而，该算法事实上须用到矩阵 A 的转置 A^T 。当须结合问题的几何结构定义和解决问题时，矩阵的转置将在数学上变得缺乏简明意义 (A 本身的数学意义简单明确：将微分算子作用在场上)，而在编程上，或代价高昂 (使用全局集总的稀疏矩阵 A) 或极其麻烦而难以实现 (转置操作脱离了算符和场本身的空间结构)。同时，数学上也可以证明，简单的双共轭梯度方法是不稳定的。因此，标准双共轭梯度方法并没有太多的实用价值。相应地，人们更常用的是由荷兰应用数学家 H. A. van der Vorst 所提出的稳定双共轭梯度法 (Bi-Conjugate Gradient Stabilized method, 一般简称 BiCGSTAB)，其数值稳定性更好、内存消耗更少、运算代价更低，最关键的是避免了 A^T 相关的运算。算法 3 不经证明地展示了 BiCGSTAB，感兴趣的读者可自行查阅相关证明。

由于稀疏矩阵相关运算的成熟和易用，许多研究者使用了基于稀疏矩阵的、具有统一接口的共轭梯度或双共轭梯度求解器。当运算仅在一个进程上进行时，这一做法虽然数值上繁琐，且稀疏矩阵的生成和存储本身将导致额外的时空开销，但仍不至于构成太大负面影响。而当运算规模较大并分布于多个进程时，这样的数据交换将会变得庞大而缓慢，令人难以接受。若交换后的数据皆在根进程运行，更会造成巨大的算力浪费，且往往会造成根节点内存告急；而交换后的数据若重新部署到各个进程上以充分利用算力，则通信代价又将大幅提高。当我们使用 CG 和 BiCGSTAB 等避开了 A^T 的方法解决微

Algorithm 3 稳定双共轭梯度 (BiCGSTAB) 算法。

```

 $r_0, r'_0, h \leftarrow Ax_0 - b$ 
 $\rho_0 = \alpha = \omega_0 \leftarrow 1$ 
 $p_0 = v_0 \leftarrow 0$ 
while  $x_l$  is not accurate enough (measured by  $r_l$ ) do
     $\rho_{l+1} \leftarrow r_0^T r_l ; \beta \leftarrow \frac{\rho_{l+1} \alpha}{\rho_l \omega_l}$ 
     $p_{l+1} \leftarrow r_l + \beta(p_l + \omega_l v_l) ; v_{l+1} \leftarrow Ap_{l+1}$ 
     $\alpha \leftarrow -\frac{\rho_{l+1}}{r_0^T v_{l+1}}$ 
     $h \leftarrow x_l + \alpha p_l ; s \leftarrow r_l + \alpha v_{l+1} ; t \leftarrow As$ 
     $\omega_{l+1} \leftarrow \frac{t^T s}{t^T t} ; x_{l+1} \leftarrow h + \omega_{l+1} s ; r_{l+1} \leftarrow s + \omega_{l+1} t$ 
end while

```

分方程问题时, 往往存在着好得多的解决方案。由前文可见, 实现共轭梯度法的核心在于计算: (a) 向量的内积 (如 $r^T r$ 形式), (b) 矩阵与向量的乘积 (如 Ax 形式)。其中, (b) 事实上就是将微分算符作用在场上, 且由前文相关算法描述可见, 其得出后无需集总、只须分散处理; 唯一需要全局集总的是 (a) 部分, 而其只须求得总和后分布于各进程即可——这一过程通信量小, 且在 MPI 等常见进程间通信系统及其接口中得到了较为深入的优化, 可通过分治算法最小化通信代价。即便在同一进程上进行运算, 我们也可以借助对向量及稀疏矩阵运算的适当包装与抽象, 借助问题本身的几何网格, 轻易而快速地完成“稀疏矩阵乘向量”或曰“微分算符作用在场上”的操作。我们将这类借助原始问题几何特性进行的共轭梯度类方法统称为“几何共轭梯度法”, 并强调其相对于必须显式生成稀疏矩阵方可进行运算的“代数共轭梯度法”在多个方面的优越性。

2.3 来自变分法的“标准答案”: 有限单元法简介

有限单元法 (也叫有限元素法, 简称“有限元”) 几乎是最负盛名、最具代表性的数值算法, 其知名度甚至使其成为了空间离散化的数值方法的代名词, 进而经常被误用——例如以“有限元”指代某计算软件或过程, 但其算法本身事实上是有限差分或有限体积法。在下面的证明中我们将看到, 有限元与其他算法 (特别是有限体积) 从计算方法到优缺点及适用范围皆存在着较为本质的不同, 故应避免混淆。

2.3.1 椭圆方程的变分形式

能量泛函

考虑一个关于 u 的二阶椭圆偏微分方程的较一般形式 (所谓斯图姆—刘维尔形式) $\nabla \cdot (p \nabla u) + gu + f = 0$, 该方程在区域 Ω 上成立, 且满足边界条件 $\partial u / \partial \hat{n} + qu = b$ (其中 $\hat{n}$ 为边界的单位外法向量, $\partial u / \partial \hat{n} \equiv \hat{n} \cdot \nabla u$)。将方程两侧先加 f 、再乘以 u 并积分, 有

$$\begin{aligned}
 \int_{\Omega} dx \, fu &= \int_{\Omega} dx \, [u \nabla \cdot (p \nabla u) + gu^2 + 2fu] = \int_{\Omega} dx \, [-p(\nabla u)^2 + gu^2 + 2fu] + \int_{\Omega} dx \, \nabla \cdot (up \nabla u) \\
 &= \int_{\Omega} dx \, \mathcal{L}(u, \nabla u, x) + \int_{\partial \Omega} d\hat{S} \cdot (up \nabla u) = \int_{\Omega} dx \, \mathcal{L}(u, \nabla u, x) + \int_{\partial \Omega} dS \, p(ub - qu^2).
 \end{aligned}
 \tag{30}$$

其中, 我们定义了拉格朗日密度 $\mathcal{L}(u, \nabla u, x)$, 并借此定义 $V_\Omega[u]$:

$$\mathcal{L}(u, \nabla u, x) \equiv -p(\nabla u)^2 + gu^2 + 2fu, \quad V_\Omega[u] \equiv \int_\Omega dx \mathcal{L}(u, \nabla u, x). \quad (31)$$

公式 (30) 及 (31) 讨论的是一般情况。考虑一个特殊但极为常用的情形: 泊松方程, 即 $\nabla^2 u = f$ 。此时 $V_\Omega[u]$ 往往是体系的**能量**。若令 u 为引力势 (此时 $f = 4\pi G\rho$), 则 $V_\Omega[u]$ 给出的是体系在 Ω 空间内的总引力势能。同样地, 若令 u 为静电势, 则 $V_\Omega[u]$ 将给出体系的总静电场能; 若令 u 为固体材料的形变场, 则 $V_\Omega[u]$ 给出的是这块材料的总弹性势能; 如此等等。人们通常将从函数到实数的映射称为**泛函** (functional), V_Ω 因而常常被称为“能量泛函”。

变分极值原理与弱解

原则上, 若系统存在稳定状态, 则其达到稳态时的能量应尽可能最低。(不算严谨地) 对应到能量泛函上, 系统所采取的状态应使泛函取极小值。若是求函数极值, 我们都会通过对函数求导获得, 而泛函的极值条件也将通过类似方法得出。考虑某个泛函 $J[u]$, 以 δ 表示**变分** (可理解为对函数形式及取值等的任意变动, 详细定义请参见泛函分析或数学物理方法教材), 并认为变分与积分、求导皆可交换:

$$\begin{aligned} \delta J[u] &= \int_\Omega dx \left[\frac{\partial \mathcal{L}}{\partial u} \delta u + \frac{\partial \mathcal{L}}{\partial \nabla u} \cdot \nabla(\delta u) \right] = \int_\Omega dx \left[\frac{\partial \mathcal{L}}{\partial u} \delta u - \nabla \cdot \left(\frac{\partial \mathcal{L}}{\partial \nabla u} \right) \delta u \right] + \int_{\partial\Omega} d\hat{S} \cdot \frac{\partial \mathcal{L}}{\partial \nabla u} \delta u \\ &= \int_\Omega dx \left[\frac{\partial \mathcal{L}}{\partial u} - \nabla \cdot \frac{\partial \mathcal{L}}{\partial \nabla u} \right] \delta u. \end{aligned} \quad (32)$$

公式 (32) 中, 第一个等号可视为对 $\mathcal{L}$ 先进行泰勒展开至 δu 的一阶后再行求导, 第二个等号借助了分部积分法 (或称高斯定理), 第三个等号是因边界条件给定后 $\partial\Omega$ 上 u 已无法任意变动故 $\delta u|_{\partial\Omega} = 0$ 。若令 $\delta J[u] = 0$ 以取得其极值, 由于 δu 的任意性, 上式将导致:

$$\frac{\partial \mathcal{L}}{\partial u} - \nabla \cdot \frac{\partial \mathcal{L}}{\partial \nabla u} = 0. \quad (33)$$

此即是**欧拉—拉格朗日方程** (Euler-Lagrange equation)。将公式 (31) 代入其中, 我们立即得到了原本的偏微分方程 $\nabla \cdot (p\nabla u) + gu + f = 0$ 。在固体力学的情形下, δu 和 δJ 对应于所谓的虚位移和虚功, 变分极值方法与**虚功法**在数学上是等效的。

值得注意的是, 泛函 $J[u]$ 只反映 u 的积分性质; 若 u 的取值与微分方程“真实”的解在一个零测度 (可以理解为“总体积”为零) 子集上存在不同 (甚至可以存在不可导的点) 则 $J[u]$ 无法反映这个差异——它仍是变分极值方法所得的解, 但与真实解不尽相同。因此, 由变分极值方法获得的解一般被称为**弱解** (weak solution)。实践上一般较少关注弱解与微分方程本身的所谓真实解之间的差异; 相反, 弱解及相应方法对不可导或间断性宽容的特性, 使其有时反而成为描述物理问题的更好方式。

“传统”变分极值问题解法

关于函数在某点数值的变动情况及其影响, 人们已有相当完备的理论和实践处理方式 (函数论、数学分析等)。然而, 泛函的相关性质却很少未经“变通”地在数值上运用, 因为体现函数空间中的“变化”是极难的。历史上, 人们最早求解变分极值问题是通过傅里叶变换 (即欧拉求解最速降线问题时所采取的方式) 求解。而用变分法求解微分方程的早期实践, 则归结于所谓的瑞利——里兹方法 (Rayleigh-Ritz method): 先借助经验大致假定解函数的形式, 并将其可能的变化用多个参数描述 (称为“试探函数”); 将这样的函数代入泛函中, $J[u]$ 在形式上就从“函数的函数”变成了常规意义下的“数字的函数”:

$$u \rightarrow u(x; \theta_0, \theta_1, \dots) \Rightarrow J[u] \rightarrow J(\theta_0, \theta_1, \dots). \quad (34)$$

最后, 通过 $\partial J / \partial \theta_i = 0$ ($i = 0, 1, \dots$) 求取这一函数的极值, 便可近似获得微分方程的解。这样的方式虽使得变分极值方法获得了实际运用, 但其求解效果以今日观点看来往往不尽理想, 求解的可靠性依赖于试探函数选取的合理性, 且计算代价也相当可观——在电子计算机普及前, 使用这一方法的科研人员们使用纸笔计算或手摇计算机, 常常须用数年时间方能完成一组准确度不甚高的求解。时至今日, 变分法在算法和设备上都取得了巨大进展: 设备方面体现为计算机技术和编程语言的总体进步, 而算法上的进展则体现在对试探函数的离散化及后继处理上。

2.3.2 变分形式的离散化

上一小节中讨论试探函数时, 设想的是参数较少故只能“全局”定义的试探函数, 其各个参数皆有“牵一发而动全身”的效果。如果具有足够的算力、允许参数数量大幅增加, 将会带来何种改变? 一个直观的想法是, 可以用**逐点定义**的方式将函数参数化——将每个点上的数值定义为一个参数。如此“参数选取”的方式可将“试探函数选取优劣”这一不确定要素对求解结果造成的影响降至最低, 但求解方案也要进行相应的调整。

一维分段线性试探函数情形

作为导入性例子, 我们仍然考虑一维泊松方程 5 的求解。此处稍微详细讨论方程的离散化。首先考虑将 $[-1, 1]$ 区间分为 N 个区间, 区间端点有 $N + 1$ 个, 坐标为 x_i 。我们首先考虑一种离散化方式: 将函数值定义在各个区间端点上 (记为 $u_i \equiv u(x_i)$ 及 $v_i \equiv v(x_i)$, 注意边界条件 $u_0 = u_N = 0$), 并令函数在各区间内取值等于两个端点值的线性内插, 即:

$$\text{对于 } x \in [x_i, x_{i+1}), u(x) = u_i + \frac{u_{i+1} - u_i}{x_{i+1} - x_i}(x - x_i) = u_i \left(\frac{x_{i+1} - x}{x_{i+1} - x_i} \right) + u_{i+1} \left(\frac{x - x_i}{x_{i+1} - x_i} \right). \quad (35)$$

从试探函数的角度看, 这一离散化方式等效于 (式中 $\Pi(t)$ 仅当 $t \in [0, 1]$ 为 t , 否则为 0):

$$u \rightarrow u(x; u_0, \dots, u_{N-1}) = \sum_{i=1}^{N-1} U_i(x), \quad U_i(x) \equiv u_i \left[\Pi \left(\frac{x_{i+1} - x}{x_{i+1} - x_i} \right) + \Pi \left(\frac{x - x_{i-1}}{x_i - x_{i-1}} \right) \right]. \quad (36)$$

记各区间宽度为 $\Delta x_{i+1/2} \equiv x_{i+1} - x_i$, 则上式中的每一项具有如下积分性质:

$$\int dx U_i = \frac{(\Delta x_{i-1/2} + \Delta x_{i+1/2})u_i}{2}, \quad \int dx U'_i U'_j = \begin{cases} u_i^2(1/\Delta x_{i-1/2} + 1/\Delta x_{i+1/2}), & j = i \\ -u_i u_{i-1}/\Delta x_{i-1/2}, & j = i - 1 \\ -u_{i+1} u_i/\Delta x_{i+1/2}, & j = i + 1 \\ 0, & \text{其他} \end{cases} \quad (37)$$

将上式代入待求解方程的变分形式, 有:

$$J[u] \rightarrow \int_{-1}^1 dx \left[-\left(\frac{du}{dx} \right)^2 + 2vu \right] = \sum_{i=1}^{N-1} \left[\frac{-u_i^2}{\Delta x_{i-1/2}} + \frac{-u_i^2}{\Delta x_{i+1/2}} + \frac{u_i u_{i-1}}{\Delta x_{i-1/2}} + \frac{u_{i+1} u_i}{\Delta x_{i+1/2}} + 2V_i u_i \right], \quad (38)$$

其中与场源 v 有关的积分项为:

$$V_i \equiv \int dx \left[\Pi \left(\frac{x_{i+1} - x}{\Delta x_{i+1/2}} \right) + \Pi \left(\frac{x - x_{i-1}}{\Delta x_{i-1/2}} \right) \right] v(x) \simeq v_i \left(\frac{\Delta x_{i-1/2} + \Delta x_{i+1/2}}{2} \right). \quad (39)$$




图 3: §2.3.2 提及的网格形态示意及示例。图中 (c) 部分同时展示了二维非结构网格下有限单元法的数据分布与依赖关系。现实应用中的准结构网格往往在图示的基础上存在较轻微的改变。

在这一“参数化”方式下，求 $J[u]$ 极值化为（注意 $\partial u_i / \partial u_j = \delta_{ij}$ ，对 u_i 求导时须考虑相邻项贡献）：

$$\left(\frac{\partial J}{\partial u_i} \right)_{\forall i} = 0 \Rightarrow -2u_i \left(\frac{1}{\Delta x_{i-1/2}} + \frac{1}{\Delta x_{i+1/2}} \right) + \frac{2u_{i-1}}{\Delta x_{i-1/2}} + \frac{2u_{i+1}}{\Delta x_{i+1/2}} = -2V_i, \forall i. \quad (40)$$

此表达式与上一章有限差分离散化形式完全一致；特别是当各区间等宽、 $\Delta x_{i+1/2} = \Delta x$ 时，有：

$$\begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & 2 & -1 & \\ & & & \ddots & \\ & & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} \begin{bmatrix} u_0 (= 0) \\ u_1 \\ u_2 \\ \vdots \\ u_{N-1} \\ u_N (= 0) \end{bmatrix} = \Delta x \begin{bmatrix} V_0 \\ V_1 \\ V_2 \\ \vdots \\ V_{N-1} \\ V_N \end{bmatrix}. \quad (41)$$

公式 (40) 及 (41) 皆可视作矩阵方程 $Au = b$ ，此处给出的 A 称为**刚度矩阵** (stiffness matrix)，而 b 称为**负载向量** (load vector) ——这两个名称来源于此方法在固体力学问题中的应用。需要注意的是，上面展现的等效性并不意味着本节讲述的方法与上一章中的方法相同——如此等效仅在一维、采用公式 (36) 所示的分段线性方式定义的试探函数的前提下成立。当我们使用不同于公式 (36) 的逐点定义试探函数（称为**形函数**，shape function）——例如分片二次插值函数——这一等效性将不复存在。

更高维情形

我们可以将上述方式拓展至更高维度。以二维为例，若我们使用矩形网格、在网格顶点定义函数值作为试探函数的“参数”并用以此为基础的线性插值函数作为形函数，则可以证明，该方法与常规有限差分方法的区别仅在于对角线上元素的引入。然而，本节所述的方法在高维下自有其优势——图 3 中展示了二维下的结构、准结构与非结构网格，这一优势将在准结构特别是非结构网格上得到显现。

仍以二维情形为例。此时最简单的几何形体为三角形；计算时，我们用不同形态的三角形单元铺满待求解区域，并将函数值定义在顶点上，如图 3 (c) 所示。对第 l 个三角形面积元素（以下简称面元，

图 3 c 中为中心绿色三角) 而言, 记其顶点的坐标为 (x_i^l, y_i^l) ($i = 0, 1, 2$), 在面元内函数值由线性插值 $u^l(x, y) = g_0^l + g_1^l x + g_2^l y$ 给出, 则可由三元线性方程组 $u^l(x_i^l, y_i^l) = u_i^l$ ($i = 0, 1, 2$), 解出 $g_{0,1,2}^l$ 作为 $u_{0,1,2}^l$ 的线性组合的组合系数矩阵: $g_i^l = G_{ij}^l u_j^l$ (此处使用了求和约定)。仿此, 我们求出图中第 m 个面元上的 u^m 、第 n 个面元上的 u^n 等各面元上的插值函数中, $g_{0,1,2}^{m,n}$ 作为 $u_{0,1,2}^{m,n}$ 的线性组合的组合系数矩阵 $G^{m,n,\cdots}$ 。我们应存储这些系数矩阵 $G^{l,\cdots}$, 以备随后使用。

在此基础上, 我们可对各面元上的形函数求导, 其在该面元内的偏导数即为 $\partial u^l / \partial x = g_1^l = G_{1j}^l u_j^l$ 及 $\partial u^l / \partial y = g_2^l = G_{2j}^l u_j^l$ 。这一结果使我们可以进一步仿照公式 (36) 至 (40) 将泛函极值问题进一步离散化, 求得对应于当前系统性质及面元分布 (也称为**网格剖分**) 下的刚度矩阵及负载向量。由图中可见, 标记为 u_0^l 的顶点, 除对绿色面元有影响外, 还对所有着蓝色的面元的形函数有影响。当我们求取刚度矩阵时, 各蓝色面元的所有顶点与 u_0^l 顶点皆会在泛函中产生重叠; 不妨记这些顶点中任意一个所对应的变量为 u^p , 则在刚度矩阵中, u^p 对应行 (列)、 u_0^l 对应列 (行) 的矩阵元将为非零, 而这些矩阵元可从上文所述的、先行存储的 $G^{\cdots}$ 矩阵中得出。

如上所述, 我们借助将变分法离散化, 把问题转化为了一个稀疏矩阵系统。这一系统可以使用代数高斯—赛德尔迭代或代数共轭梯度等方法求解。而若要进行分布式运算且在运算效率或空间占用方面不无需求, 则同样可以论证, “稀疏矩阵乘向量” 的操作在离散化变分法的框架下, 事实上仍是局域地作用在当前子网格 (加上 “一圈” 围绕之的格点) 上的运算和操作。因而, 离散化变分法仍可以纳入几何方法求解 (包括几何高斯—赛德尔迭代、几何共轭梯度) 的范畴内, 以最大化其在分布式内存系统上的并行求解效率。在三维下, 三角形面元被四面体型体元取代 (例如图 3 d), 而上述基本思路仍维持不变。但无论在何种情形, 网格剖分的求取、在此基础上刚度矩阵及负载向量的构建, 皆构成了本节所述离散变分方法的核心。

有限单元法小结

在保证效率的基础上, 本节所述方法的优势很大程度上在于三角形面元或四面体型体元较强的适应性。若求解体系几何结构较为复杂, 且存在须用更密集网格求解的局部区域, 则这些元素组成的**非结构网格**能够较好适配², 在非结构网格下, 基于数值求离散化的有限差分方法会变得极端繁复、效果不彰。而正是因为按离散化的变分法具有容易适配非结构网格、对间断性较为宽容的优势, 此方法在工程技术领域取得了极其普遍的应用, 并打出了**有限单元法** (或称有限元素法, 简称**有限元**) 的威名。

但正如本节开头所强调的, 在数值计算研究中, 我们不应将有限元与其他偏微分方程数值算法混淆。有限元法本身的成立依赖于泛函极值的存在及唯一性, 而这对微分方程本身的性质是有要求的, 如双曲方程就很难被纳入这一框架中 (虽然数学上可以对双曲方程配平方, 但此时体系条件数也将变为原来的平方)。二维以上问题的刚度矩阵求解往往须依赖迭代方法, 其完全收敛一般较为缓慢, 而不完全的收敛对极其重视守恒律的双曲方程问题而言不啻一场灾难。在天体物理上, 最重要的 (磁) 流体动力学问题属于有限元并不擅长的双曲问题; 即便是求解椭圆方程 (如流体的自引力问题, 或经过时间离散转化为亥姆霍茨方程的辐射场扩散问题等), 也一般无须处理复杂的几何结构, 因此经常无需非结构网格, 难以体现有限元的优势。这些椭圆方程的求解又往往与 (磁) 流体力学直接耦合, 若该动力学部分建立在结构网格上, 则有限元或 (a) 须单独建立一套网格进而额外占用大量内存, 并与动力学网格相互投影因而变得麻烦且不准确, 或 (b) 须适配结构网格而变得与有限差分方法差异不大, 或因采用高阶形函数而变得较为复杂。总之, 因为有限单元法的优势不易体现、缺点常被放大, 其在天体物理中的

² “横平竖直” 的结构网格处理复杂几何结构、局部网格细化亦有相应方法, 但相比之下复杂性稍高, 且在求解椭圆问题时效果不尽理想。不过, 椭圆问题缺乏守恒律, 而非结构网格的劣势正是在于难以很好处理守恒律。因此, 在下一章涉及的双曲问题中, 非结构网格的优势并不明显, 但劣势却被放大了。

应用较为受限。一个常见的重要应用，是在用质点网格法 (particle-in-cell method, 简称 PIC) 进行等离子体模拟时，用于计算电荷及电流密度并基于此求解电磁场的非结构网格上的运算中。

总之，有限单元法是一种强而有力的、主要用于求解椭圆问题的数值方法。其数学本质为离散化的变分法：通过逐点定义函数取值并借助插值给出试探函数形式，再对作为参数的函数各点取值进行“优化”以最小化目标泛函，进而求得微分方程的弱解——这也是冯康先生提出有限单元法的伟大论文《基于变分原理的差分格式》所取标题的含义。有限单元法的优缺点都较为突出，使用与否、如何使用，皆须因地制宜、具体分析。

2.4 有限差分迭代方法与多重网格：另一个“标准答案”

在常微分方程一章中，我们已经介绍了有限差分方法在求解边值问题中的应用，并讨论了雅可比迭代、高斯—赛德尔迭代两种求解方式。在当时的实际运用例中我们发现，高斯—赛德尔迭代的收敛速度明显快于雅可比迭代，但即便如此，在分辨率仅为 $N = 32$ 的一维网格上，泊松方程的收敛就花费了约 500 次迭代。是否有加速收敛的方式呢？一般的数值计算教程中会介绍超松弛迭代 (successive over relaxation, 简称 SOR) 方法，可理解为在每次高斯—赛德尔迭代中“修改”各个 u_i 的数值时，把原先迭代方法所对应的 Δu_i 乘以一个大于 1 且通常小于 2 的系数再添加到 u_i 上的做法。这一方法确实有加速迭代收敛之效，但距离理想、快速的解法仍然有较大差距。我们应当如何改进？

2.4.1 红黑高斯——赛德尔迭代




图 4: 二维下红黑高斯—赛德尔迭代网格示例 (§2.4.1)。

本小节首先介绍一个常用的、在高斯—赛德尔迭代基础上进一步加速并有利于并行计算的方法。若希望在共享内存模型 (shared-memory model, 通常是多线程编程, 常见如 OpenMP) 上计算, 或针对现代化的异构设备 (包括单指令多数据 SIMD 设备, 或图形处理器 GPU 设备等) 进行编程, 则标准高斯—赛德尔迭代所具有的数据依赖性将使得计算几乎无法进行——例如, 在一维下, $u_i^{(l+1)}$ 依赖于原则上应当同时处于计算状态中的 $u_{i-1}^{(l+1)}$, 高维类推。在并行计算时, 此种依赖性将经常性导致数据的读写冲突 (称为竞态条件, race condition), 该冲突会直接导致数据错误——这类错误甚至会让数值出现在完全错误的量级或符号上 (特别是

考虑通行的浮点数记录方式常将符号和指数前置, 见图 5)。

此时, 人们常用的方法为所谓**红黑高斯—赛德尔迭代** (red-black Gauss-Seidel iteration, 简称 RBGS)。其基本思路为, 将各格点分为交替的红点和黑点, 并保证红点周围只有黑点、黑点周围只有红点 (在二维下形如国际象棋的棋盘, 所以也有人称其为“棋盘法”, 如图 4 所示)。在实际操作中分配红黑点时, 有一个简易的操作方式: 将格点的各维度指标求和 (如三维下对应于 u_{ijk} , 该求和即为 $i + j + k$), 若为偶数则为黑点, 奇数则为红点。迭代进行过程中, 在偶数步 (包括第 0 步) 时只进行改变黑点数据的运算, 而在奇数步时只进行红点的运算。容易发现, 在进行黑点运算时, 任意黑点的结果仅取决于红点的数值, 于是同一时刻其他线程所进行的黑点求解并不会对当前线程的求解过程造成干扰; 进行红点运算时亦然。人们经过分析发现, 若将黑、红相继进行一次运算称为一次迭代, 则其收敛速度甚至快于“标准”的高斯—赛德尔迭代。




图 5: 常见单精度 (FP32) 与双精度 (FP64) 浮点数记录方式: 白色为符号, 绿色为指数, 红色为真数。

2.4.2 多重网格方法

在常微分方程一章中, 我们粗略地给出过雅可比迭代或高斯—赛德尔迭代的收敛原理, 但并没有详细分析收敛速率。为方便起见, 我们此处以一维均匀网格为例进行分析; 如前文所述, 一个泊松方程, 其微分算符对应的 $N \times N$ 矩阵 A 及其本征序列为:

$$A = \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & 2 & -1 & \\ & & \ddots & \ddots & \\ & & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix}, \quad \begin{array}{ll} \text{本征值} & \lambda_i^A = 1 - 2 \cos\left(\frac{i\pi}{N}\right) \\ \text{本征向量} & \mathbf{e}_i = \left[\sin\left(\frac{ij\pi}{N}\right) \right]_{\forall j} \end{array} \quad (42)$$

上式中的本征向量记法指其第 j 个分量取值。容易发现, 上式其实对应着傅里叶分析——直角坐标系下的拉普拉斯算符, 其本征函数即是三角函数。

同上一章, 我们将矩阵 A 分解为上下三角与对角部分 $A = D + L + U$, 此时对应于雅可比方法的迭代矩阵为 $R = -D^{-1}(U + L)$ 。可以验证, R 的本征向量组与 A 相同, 而对应于本征向量的第 i 个本征值则为 $\lambda_i = 1 - 2 \sin^2(i\pi/2N)$ 。将初始残差按上述本征系统展开, 则在 m 次迭代后:

$$e^{(m)} = R^m e^{(0)} \equiv R^m \sum_{i=1}^{N-1} c_i \mathbf{e}_i = \sum_{i=1}^{N-1} (\lambda_i^m c_i) \mathbf{e}_i. \quad (43)$$

固然, 因对各 $0 < i < N$ 皆有 $|\lambda_i| < 1$, 上式中的迭代后展开系数 $\lambda_i^m c_i$ 终将随着 m 的增加而趋于零, 但经观察容易发现, 对相同的 N , i 越小, 则 λ_i 越趋于 1, 在残差的分解中所对应项的迭代收敛越困难。在数学图像上, i 越小、“波数”越小, 意味着对应的三角函数形式本征向量的波长越长³。当我们进行雅可比迭代时, 每次进行的操作是让每一个点仅与其邻居交换信息, 故小尺度的残差可以快速抹平, 但大尺度上需要多次迭代方可真正传递信息, 这些尺度上的残差抹平所需迭代次数大幅增加。回顾上一章的微分方程求解实践的相应图示可发现, 近似解确实小尺度上快速地趋于其最终结果, 但更加“整体性”的幅度直到很晚方才与“真实解”趋于一致。对于高斯—赛德尔迭代, 可以验证,

$$\lambda_i^G = \cos^2\left(\frac{i\pi}{N}\right) = \left[1 - 2 \sin^2\left(\frac{i\pi}{2N}\right)\right]^2, \quad \mathbf{e}_i = \left[\cos^j\left(\frac{i\pi}{N}\right) \sin\left(\frac{ij\pi}{N}\right) \right]_{\forall j}, \quad (44)$$

³注意, 此处暂未讨论 $N/2 < i < N$ 区间内的所谓混叠 (aliasing) 现象, 但相应的波数可简单作 $\pi - i\pi/2N$ 处理。




图 6: 公式 (5) 所示的一维泊松方程借助多重网格法求解时, 系统状态的演变示例。该求解仅经历一次多重网格循环即告收敛。

可见其收敛速度固然快于雅可比方法, 但“长波残差收敛慢”的问题仍然存在。

我们通过观察上述结果发现, 对于更大的 N , 长波下的 λ_i 与 λ_i^G 都更接近于 1, 导致迭代收敛更为困难。这一结论向我们提示了解决收敛速度问题的可能方案: 在更大的尺度、更粗的网格 (对应于更小的 N) 上先行大致解决问题, 再将结果逐步细化, 在越来越小的尺度上解决对应尺度的问题, 进而使各尺度上收敛都得到加快? 顺应这一思路, 人们提出了**多重网格方法** (multi-grid method, 简称 MG)。

粗化与细化——“限制”与“延拓”

考虑一个长度为 $N = 2^L$ 的均匀一维网格。直观上, 多重网格法可以如此构建: 首先在最粗糙的、只有 2 个格点的网格上迭代至收敛, 再将其作为初始结果, 插值至 4 个格点的次粗糙网格上迭代至收敛, 如此逐层类推, 直至最细的网格。这一思路虽未必不可行, 但仍然存在一些不易克服的问题: (a) 源项在粗网格下的表现形式须仔细推导、定义以避免数学上的错误; (b) 细网格上的行为事实上会对粗网格构成影响, 以上步骤其实忽略了这一事实, 对收敛性不利。事实上, 在解决线性椭圆方程时, 人们常常使用所谓**残差多重网格** (residual multi-grid method) 的方法, 层间仅传递残差及修正。这一方法快速、可靠、编程也相对简便, 成为了多重网格法范畴内的标准解法——除非须解决准线性问题。

残差多重网格法的过程如下。记问题为 d 维, 并记每个维度上具有 2^l 个格点的网格为第 l 层, 则第 0 层为最粗糙 (仅有一个格点), 而第 L 层为最细密 (具有全部 N 个格点)。首先, 在第 L 层上进行 m 次迭代求解 (可以是雅可比、高斯—赛德尔、红黑等方法, 通常使用红黑高斯—赛德尔迭代)。求解结束后, 因体系未完全收敛, 可由当前得到的第 L 层上的近似解 u^L 计算残差——数学上等效于求

- 同样，在延拓后的更“精细”一层上，由于“黑色”点上的数值将立即以“红色”点及当前场源为输入进行“刷新”，求“黑色”点上的延拓没有意义，故延拓仅须对更细一层的“红色”点进行。
- 若求解的是非线性（包括准线性或半线性）方程，原则上残差多重网格将会失效，故人们常用“完整”的多重网格方法求解（常称为 full approximation storage，简称 FAS）。当涉及局部网格细化时，残差多重网格法仍可以进行，但对粗细网格的边界的处理应格外当心，故有人为避免麻烦也常采用完整多重网格。限于篇幅，此处不做讨论，对完整方法有兴趣者可搜索相关文献阅读。

2.5 抛物方程哪儿去了？

在本章开头，我们讨论了偏微分方程的分类，并声明将在下一章处理双曲型方程。然而到目前为止，本章只讨论了椭圆型方程，而并未涉及另一个重要的种类——抛物型方程。从物理角度看，抛物型方程的适用范围相当大。在天体物理研究中最常见的抛物方程是扩散方程：

$$\frac{\partial u}{\partial t} + \nabla \cdot (D \nabla u) = \frac{\partial u}{\partial t} + D \nabla^2 u + (\nabla D) \cdot (\nabla u) = 0. \quad (45)$$

其中， u 是参与扩散的物理量， D 是相应的扩散系数（可为空间位置、 u 的取值等参量的函数），具有 $[L]^2[T]^{-1}$ 的量纲。除了令 u 为最常见的粒子数密度、用方程表达粒子在浓度梯度下驱动的扩散外，上式中的 u 还可为动量密度（此时方程表征的物理现象为流体粘滞）、内能密度（表征热传导）、磁感应强度矢量（表征磁扩散，或称非理想磁流体力学效应，non-ideal MHD effects），或可在光子平均自由程足够短时表达辐射场的行为⁴。甚至，经过合适的适配，扩散方程还可对应于薛定谔方程，并用于表征含时的量子力学问题。

2.5.1 抛物方程的有限差分求解

求解抛物方程的一个简单想法是将其等效为常微分方程处理：例如，基于当前的 u 计算公式 (45) 中的空间导数项，并借此得出 $\partial_t u$ 在当前 u 下的值，继而直接使用常微分方程的方法求解。这一方法被称为抛物型方程求解的有限差分法，其具体方法往往使用对应的常微分方程求解方式指代。

既然求解方式等同于常微分方程，则抛物型方程的求解是否稳定、准确，也可以用类似常微分方程初值问题的方式判定。但由于抛物方程中给出时间导数的项的形式较为固定，我们反而可以得出更为确定的结论。若在一个一维均匀网格上使用显式欧拉法，假定扩散系数 D 是常数，记格点长度为 Δx 并取步长为 Δt ，则可将单步时间演化 $u \rightarrow u'$ 写为离散形式：

$$u'_i = u_i + \frac{D\Delta t}{\Delta x^2}(u_{i+1} + u_{i-1} - 2u_i), \quad (46)$$

并进一步将其表示为矩阵形式 $u' = Au$ ，其中 $d \equiv D\Delta t/\Delta x^2$ ，而

$$A = \begin{bmatrix} 1-2d & d & & & \\ & d & 1-2d & d & \\ & & d & 1-2d & d \\ & & & \ddots & \\ & & & & d & 1-2d & d \\ & & & & & d & 1-2d \end{bmatrix}. \quad (47)$$

⁴ 此时辐射场的状态称为扩散极限，但有时求解域内存在平均自由程较长的区域，为了让扩散速度在这些区域不至于超光速，一般会对扩散系数有所限制而非简单令其为 $D = \lambda c$ ——这一算法称为限流扩散（flux-limited diffusion，简称 FLD）。

可以验证, A 的最大绝对值的本征值为 $|\lambda|_{\max} = |4d - 1|$ 。在 m 步迭代后, $u^{(m)} = A^m u^{(0)}$; 为使 m 很大时 $u^{(m)}$ 不至于发散, 我们要求 $|\lambda|_{\max} \leq 1$, 由此得稳定性条件 $2d < 1$, 进而得出 $\Delta t < \Delta x^2 / (2D)$ 。从物理图像的角度看, 相邻两格点间的浓度梯度为 $|\Delta u| / \Delta x$, 由此梯度驱动的扩散速度为 $v_D \equiv D(|\Delta u| / \Delta x) / |\Delta u| = D / \Delta x$ 。因此稳定性条件等效于 $v_D \Delta t < \Delta x / 2$, 即每一步时间演化中扩散所发生的空间尺度不应大于半个格点宽度。可以论证, 类似的条件 $\Delta t < C[\Delta x^2 / D]_{\min}$ 对更高维度、可变扩散系数 D 的扩散方程构成求解稳定条件, 其中的安全系数 C 一般须取在 0.5 以下。

2.5.2 抛物方程的隐式格式

当扩散系数较大, 上一小节所述的稳定性条件将给出极小的 Δt 。在此基础上, 若扩散系数变化范围较大, 或扩散方程求解须适配与其耦合的其他问题 (如流体力学), 极小的 Δt 将给问题的求解带来极大的计算代价。类比于常微分方程中的做法, 此时我们应当用隐式或半隐式方法尝试解决问题。简单的反向欧拉纯隐式方法可在上一小节的均匀网格常系数扩散方程框架下写为

$$u'_i = u_i + \frac{D\Delta t}{\Delta x^2} (u'_{i+1} + u'_{i-1} - 2u'_i), \quad (48)$$

并表达为矩阵形式 $Mu' = u$, 其中 M 可写为:

$$M = \begin{bmatrix} 1+2d & d & & & \\ d & 1+2d & d & & \\ & d & 1+2d & d & \\ & & & \ddots & \\ & & & d & 1+2d & d \\ & & & & d & 1+2d \end{bmatrix}. \quad (49)$$

与常微分方程一章中的分析类似, 反向欧拉法稳定, 但精度仅为一阶, 不一定会给出足够准确的结果。于是人们将常微分方程问题中的隐式中点法引入, 将问题离散化为:

$$u'_i = u_i + \frac{D\Delta t}{2\Delta x^2} [(u'_{i+1} + u'_{i-1} - 2u'_i) + (u_{i+1} + u_{i-1} - 2u_i)]. \quad (50)$$

这样半隐式的离散化格式称为**克兰科—尼克尔森格式** (Crank-Nicolson method, 简称 CN), 其矩阵形式为 $Mu' = Au$, 但须对其中的 d 进行置换: $d \rightarrow D\Delta t / 2\Delta x^2$ 。人们论证, 克兰科—尼克尔森格式的稳定性条件与显式方法大致相同, 但安全系数可取较大数值。由于公式 (48) 与 (50) 事实上可等同于亥姆霍茨方程的离散化 (等价地, M 和 A 皆可对应于亥姆霍茨方程的微分算符), 故 (半) 隐式抛物方程求解可完全被纳入椭圆方程的框架中, 进而使用本章前面论述的方法求解。

习题

注意: 请尽量以本章讲解或题目中要求的方法完成此次作业。请勿直接使用 OpenFEM 等成熟的求解软件或 Matlab 的偏微分方程库, 否则不得分。

本章习题使用特殊的方式布置。给定相同的二维泊松方程问题

$$\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = v(x, y), \quad u|_{x=\pm 1} = u|_{y=\pm 1} = 0, \quad v(x) = \Theta(0.25 - \sqrt{x^2 + y^2}), \quad (51)$$

请在下列选项中选择一种解决此问题并绘制求解结果:

1. 使用傅里叶变换方式求解。若选择此方法，请自行实现一个一维的快速傅里叶变换。注：如果由 C++ 等现代化编译型语言实现且质量较高、适合并行化改造，你可能会在以后的科研实践中真正运用并不断改进这个实现。
2. 使用有限单元法求解。若选择此方法，你可以使用结构网格或“准结构”网格，也可挑选一个网格生成器使用（但请勿直接使用现成软件求解!）。
3. 使用共轭梯度法实现。若选择此方法，为简化问题，请保证微分算符所对应的矩阵是对称的。
4. 使用基于迭代的有限差分法，并以多重网格方式实现求解。注意，多重网格法通常是本列表中最难以实现的方法。

参考文献

Press, W. H., Teukolsky, S. A., Vetterling, W. T., & Flannery, B. P. 2002, Numerical recipes in C++ : the art of scientific computing (Cambridge University Press)